

Mis apuntes de misterio

Robert Remond.

► DEFINICIONES PREVIAS

- ↳ Población objetivo: Todas las unidades de interés
- ↳ Muestra: Subconjunto de la población (aleatoria / No Aleatoria)
- ↳ Unidad de Muestreo: Objeto a ser seleccionado q' permite el acceso a la información.
- ↳ Unidad de observación: Personas: $\rightarrow y_1$: sexo, y_2 : educación, y_3 : NIE, ... y_k .
Hogares:
Viviendas:
- ↳ Operación Estadística: Hay 3
 - ① Contros
 - ② Registros Administrativos; Documentación auxiliar proveniente de otra fuente (Ej: Recibos de clientes de un banco). Al tomar una muestra de esto se tiene un marco muestral.
 - ③ Encuestas: Estimaciones de θ q' son funcionales del total (T_y)
se accesa a los elementos a través de un algoritmo de selección.
Cada uno de los elementos de la muestra son observados.
 y_1, y_2, \dots, y_k
 - Cada uno de los valores grabados de la variable son usados para estimar los parámetros.
 - ④ Marcos: De listas / De áreas (cartografía)

► FICHA TÉCNICA: [DISEÑO MUESTRAL]

Razona la calidad de la encuesta.

Contiene:

- ① Población Objetivo
- ② Muestra (características) ?
- ③ Unidad de muestra
- ④ Unidad de observación
- ⑤ Variables de interés (Breve descripción)
- ⑥ Descripción del marco de muestra
- ⑦ Parámetros de interés
- ⑧ Diseño de muestra (si la encuesta es probabilística)
si no es probabilística entonces la técnica de recolección de datos.
- ⑨ Tamaño de la muestra
- ⑩ Nivel de Confianza
- ⑪ Error de muestra;

- Error Estándar: $\sqrt{v(\hat{\theta})}$

- Margen de Error: $Z_{1-\alpha/2} \sqrt{v(\hat{\theta})}$

- Coeficiente de Variación: $\frac{\sqrt{v(\hat{\theta})}}{\hat{\theta}}$ \Rightarrow No aplica para proporciones
 $p < 0,3$; $p > 0,7$

► POBLACION FINITA:
 Un conjunto de n elementos $\{e_1, e_2, \dots, e_N\}$ donde N no es necesariamente conocido y ademas N es finito ($N \leq 100$) y $U = \{1, 2, \dots, N\}$ es el conjunto de rótulos.

► MUESTRA ALEATORIA SIN REEMPLAZO:
 Subconjunto de la población, extraido mediante un mecanismo de selección estadístico.

$S \rightarrow$ variable aleatoria
 $s \rightarrow$ realización de S

Ejemplo:
 Muestreo aleatorio y sin reemplazo
 $U = \{\text{Cristiano, Messi, Falcao, Iniesta, Xavi}\}$

Una muestra s de $n=2$ puede ser:

$s = \{ \text{Falcao, Xavi} \} \rightarrow$ lo vamos a representar por un vector columna de 1's y 0's.

$$s_i = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 1 \end{pmatrix} \rightsquigarrow \text{Esta es una realización de } S.$$

Entonces una muestra aleatoria sin reemplazo se denota como:

$$S = \begin{pmatrix} s_1 \\ s_2 \\ \vdots \\ s_N \end{pmatrix} \in \{0, 1\}^{N \text{ dimensional}}$$

donde cada componente $s_k \in \{1 \text{ si } k \in s, 0 \text{ si } k \notin s\}$ > En muestreo sin reemplazo

↳ Quién sería S ?

Retomando nuestro ejemplo de $n=2$

$$S = \left[\begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \\ 0 \\ 1 \\ 0 \end{pmatrix} \dots \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 0 \end{pmatrix} \dots \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} \right] \Rightarrow S = \begin{pmatrix} 1 \\ 2 \\ \vdots \\ 10 \end{pmatrix} = 10$$

El conjunto S tiene 10 vectores o 10 elementos y cada vector tiene 5 componentes

► **TAMANO DE LA MUESTRA:** Denotamos con $n(s)$ el tamaño muestral de una muestra en particular s , donde s es una realización de S .

$$n(s) = \sum_{k \in s} 1$$

entonces

$$s = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} \Rightarrow n(s) = 2.$$

► **MUESTRAS ALEATORIAS CON REEMPLAZAMIENTO:**

columna

$$s = \begin{pmatrix} s_1 \\ s_2 \\ \vdots \\ s_{n-1} \\ s_n \end{pmatrix} \in \mathbb{N}^n$$

Identificadas mediante el vector

donde s_k representa el número de veces q el elemento k se encuentra contenido en la muestra.

Ej: Continuando con los jugadores

con $m=3$

$$s_1 = \begin{pmatrix} 0 \\ 2 \\ 0 \\ 0 \\ 1 \end{pmatrix} \Rightarrow s_1 = \{ \text{messi}, \text{messi}, \text{xavi} \}$$

con $m=7$

$$s_2 = \begin{pmatrix} 2 \\ 3 \\ 0 \\ 2 \\ 0 \end{pmatrix} \Rightarrow s_2 = \{ \text{cristiano}, \text{cristiano}, \text{messi}, \text{messi}, \text{messi}, \text{iniesta}, \text{iniesta} \}$$

$m = \text{tamaño de la muestra pero muestra con reemplazamiento}$

$m > n$ se puede dar, s decir, puede haber mayor muestra q elementos incluidos en la misma.

En este caso el tamaño de muestra efectivo es $n=3$, q cada elemento seleccionado lo aplica solo una vez la medición y la repite K veces segun q se seleccionado en la muestra m .

► **TIPOS DE MUESTREO**

↳ Con reemplazo

↳ Sin reemplazo

► **TAMANO DE LA MUESTRA**

↳ Fijo

↳ Aleatorio

SOPORTE (Q):

Se trata de un conjunto de todas las muestras posibles y es lo que en teoría de probabilidad conocemos como el Álgebra de Eventos.

Ej: $U = \{(\text{mou}, \text{pep}), (\text{del bosque})\}$, el soporte tiene:

$$Q = \left\{ \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right\} \Rightarrow \text{en este soporte tenemos todas las posibles muestras sin reemplazo}$$

$n=0, n=1, n=2, n=3.$

Lexicográficamente, este soporte es:

$$Q = \{\emptyset, (\text{mou}), (\text{pep}), (\text{del bosque}), (\text{mou}, \text{pep}), \dots, (\text{mou}, \text{pep}, \text{del bosque})\}$$

Este soporte ej. vimos se caracteriza por contener todas las combinaciones posibles entre elementos.

Los Soportes Simétricos:

Se dice simétrico un soporte, si para cualquier $s \in Q$ todas las permutaciones de los elementos que componen a s están contenidas en Q , es decir, todas las posibles muestras de tamaño n , están contenidas en el soporte. Hay varios tipos:

③ Soporte simétrico sin reemplazo:

$$Q = \left[\begin{pmatrix} s_{11} & s_{12} & \dots & s_{1j} \\ s_{21} & s_{22} & \dots & s_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{nj} \end{pmatrix} \right] \in [0, 1]^N \quad \text{se define como}$$

y su tamaño se calcula como

$$\# Q = 2^N$$

Ej: $U = \{(\text{mou}, \text{pep}), (\text{del bosque})\}$, entonces $\# Q = 2^3 = 8$ (Verificar según ejemplo anterior)

④ Soporte simétrico sin reemplazo de tamaño fijo:

$$S_n = \left\{ s \in S \mid \sum_{k=1}^n s_{kk} = n \right\} \quad \xrightarrow{\text{que cumple}}$$

se define como:

y su tamaño se define como

$$\# (S_n) = \binom{N}{n}$$

Ejemplo:

$$N=3 \quad \text{y} \quad n=2$$

$$S_n = \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\} \Rightarrow \# (S_n) = \binom{3}{2} = 3$$

$$\left| \begin{array}{c} N=3 \quad n=1 \\ S_n = \left\{ \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\} \\ \# (S_n) = \binom{3}{1} = 3 \end{array} \right.$$

② Soporte simétrico con reemplazo:

Se define por:

$$\mathcal{R} = \mathbb{N}^{\mathbb{N}}$$

$\mathbb{N} \in \text{Naturales}$

donde $\#(\mathcal{R}) = \infty$

③ Soporte simétrico con reemplazo de tamaño fijo:

Se define por:

$$\mathcal{R}_n = \left\{ s \in \mathcal{R} \mid \sum_{k=0}^{\infty} s_k = n \right\}$$

y su tamaño se calcula como:

$$\#(\mathcal{R}_n) = \binom{n+m-1}{m} = \binom{n+m-1}{n-1}$$

ya q' si T es el total de posibles soluciones no negativas ($x_i \geq 0$) de la ecuación $x_1 + x_2 + \dots + x_r = n$, entonces

$$T = \binom{n+r-1}{r-1} = \binom{n+r-1}{n}$$

Ej:

Si $N=3$ $\rightarrow N = \{e_1, e_2, e_3\}$

para $m=4 : \{e_1, e_2, e_3, e_3\}$

+ los cajones q' dividen
son $N=1$.

$$\begin{array}{ccccccc} e_1 & e_2 & e_3 & e_3 \\ * & * & * & * \\ \downarrow & \downarrow & \downarrow & \downarrow \\ 1 & 2 & 3 & 4 & 5 & 6 \end{array} \Rightarrow \binom{m+N-1}{m} = \binom{6}{4} = 15$$

para $m=3 \Rightarrow \{e_3, e_3, e_3\}$

$$\begin{array}{ccccccc} e_1 & e_2 & e_3 & e_3 & e_3 \\ \emptyset & \emptyset & * & * & * \\ \downarrow & \downarrow & \downarrow & \downarrow & \downarrow \\ 2 & 3 & 4 & 5 \end{array} \Rightarrow \binom{m+N-1}{m} = \binom{5}{3} = 10$$

y viene del principio binomial de conteo; De cuantas formas puedo organizar los objetos en los cajones?

Resumen:

↳ Muestras con reemplazo (El orden importa)

$$N^K$$

↳ Muestras con reemplazo (El orden no importa)

$$\binom{m+N-1}{m} = \binom{m+N-1}{n-1}$$

✓ USAMOS.

↳ Muestreo sin reemplazo (orden importa)

$$nPk = \frac{n!}{(n-k)!} \quad X$$

↳ Muestreo sin reemplazo (orden no importa)

$$\binom{n}{k} = \frac{n!}{(n-k)!k!} \quad \checkmark \quad \text{USAMOS.}$$

Ejemplo:

$$\text{Si } N=3 \quad U=\{\text{mov, pep, del basque}\} \quad \text{y } m=4$$

$$\#(R_u) = \binom{4+3-1}{4} = \binom{6}{4} = \binom{6}{2} = 15$$

$S = \{(\text{mov, mov, mov, mov}), (\text{pep, pep, pep, pep}), (\text{db}, \text{db}, \text{db}, \text{db}), (\text{mov, mov, mov, pep}), (\text{mov, mov, mov, db}), (\text{mov, mov, pep, pep}), (\text{mov, mov, db, db}), (\text{mov, mov, pep, db}), (\text{mov, pep, pep, pep}), (\text{mov, db, db, db}), (\text{mov, pep, pep, db}), (\text{mov, pep, db, db}), (\text{pep, pep, pep, db}), (\text{pep, pep, db, db}), (\text{pep, db, db, db})\}$

► DISEÑO DE MUESTREO: $p(\cdot)$

Teniendo un soporte de muestras, es posible establecer la probabilidad de selección de una muestra dada S [$p(S)$].

A la larga, esto quiere decir q. al mínimo) da existencia de una función $p(\cdot)$ q' alguna una probabilidad de selección $p(S)$ de una muestra S contenida en el soporte.

$$Q \xrightarrow[\text{con } p(S) > 0]{\text{def}} (0, 1] \quad \forall S \in Q$$

Ejemplo:

$$\text{Para } N=5 \quad n=2 \Rightarrow \text{sin reemplazo} \Rightarrow \#Q = \binom{5}{2} = 10$$

	I_1	I_2	I_3	I_4	I_5	$p(S)$
1	1	1	0	0	0	0,13
2	1	0	1	0	0	0,2
3	1	0	0	1	0	0,15
4	1	0	0	0	1	0,1
5	0	1	1	0	0	0,15
6	0	1	0	1	0	0,09
7	0	1	0	0	1	0,02
8	0	0	1	1	0	0,06
9	0	0	1	0	1	0,07
10	0	0	0	1	1	0,08

• donde $\sum_{S \in Q} p(S) = 1$.

• $\forall p(S) > 0$ para todo $S \in Q$

son características q. SIEMPRE se deben cumplir.

En Muestreo la variable aleatoria son vectores, y cada vector tiene una probabilidad conocida y designada.

EJERCICIO

① Considera $U = \{mou, pep, del borgue\}$ y un muestra con reemplazamiento de tamaño $n=2$

④ Escribe el soporte R de manera vectorial

$$R = \left\{ \begin{pmatrix} 2 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 2 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} \right\}$$

⑤ Escribe de manera lexicográfica el soporte.

$$R = \{(mou, mou), (pep, pep), (del borgue, del borgue), (mou, pep), (mou, del borgue), (pep, del borgue)\}$$

② Considera $U = \{mou, pep, del borgue, pekemon, Bielba, Simeone\}$ y un muestra sin reemplazamiento de tamaño $n=3$

⑥ Escribe el soporte Q de manera vectorial

$$Q = \left\{ \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 1 \end{pmatrix} \right\}$$

$$\left\{ \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \right\}$$

⑦ Escribe de manera lexicográfica el soporte

$$Q = \{(mou, pep, del borgue), (mou, pep, pekemon), (mou, pep, Bielba), (mou, pep, Simeone) \\ (mou, del borgue, pekemon), (mou, del borgue, Bielba), (mou, del borgue, Simeone), (mou, pekemon, Bielba) \\ (mou, pekemon, Simeone), (mou, Bielba, Simeone), (pep, del borgue, pekemon), (pep, del borgue, Bielba) \\ (pep, del borgue, Simeone), (del borgue, pekemon, Bielba), (del borgue, pekemon, Simeone), (pep, Bielba, Simeone) \\ (del borgue, Bielba, Simeone), (pekemon, Bielba, Simeone), (pep, pekemon, Bielba), (pep, pekemon, Simeone)\}$$

③ Considera una población de tamaño $N=10$ y con una muestra de tamaño r calcula la cardinalidad de los respectivos soportos para la muestra:

↳ Con reemplazo

$$\# R = \binom{m+N-1}{m} \Rightarrow \frac{m=r}{N=10} \Rightarrow \# R = \binom{r+10-1}{r} = \underline{\underline{2002}}$$

↳ Sin reemplazo

$$\# Q = \binom{N}{n} = \binom{10}{r} = \underline{\underline{252}}$$

► DISEÑO DE MUESTREO P(ω):

Es una función f

$$Q \xrightarrow{f} (0, 1]$$

Es una función de probabilidad multivariada sobre Q. Las propiedades del diseño de muestras son:

i) $\sum_{s \in Q} p(s) = 1$

ii) $p(s) > 0$

Si $p(s)=0$ no es un diseño de muestras probabilísticas para algún s .
Según como sea el ropero tendremos:

- Muestreo con reemplazo

- Tomando fijo $n(s) = n$

- De tomarlo aleatorio.

- Muestreo sin reemplazo

- De tomarlo fijo $n(s) = n$

- De tomarlo aleatorio

↳ Algoritmo de selección de la muestra:

utilizado para seleccionar una muestra probabilística. Es un mecanismo estadístico

► PROBABILIDAD DE INCLUSIÓN:

la inclusión es un evento aleatorio el cual se define por la función indicadora

$$I_{k(S)} = \begin{cases} 1 & \text{si } k \in S \\ 0 & \text{si } k \notin S \end{cases}$$

Donde la función $I_{k(S)}$ es una función de la variable aleatoria S.

Las probabilidades de inclusión pueden ser:

↳ De Primer Orden: (π_k)

el k^{er} uno, elemento de la población $\{e_1, e_2, \dots, e_n\}$ pertenezca a la muestra aleatoria. Esto se define como la probabilidad de q'

$$\pi_k = P(k \in S) = P(I_{k(S)} = 1) = \left[\sum_{s \in S} I_{k(s)} p(s) \right] = \sum_{s \in S} p(s)$$

Ejemplo: (sin reemplazo):
 para $U = \{Cristiano, Messi, Falcao, Iniesta, Xavi\} \rightarrow N=5$ con $n=2$
 → El tamaño del espacio es $\#Q = \binom{5}{2} = 10$

id	I_1	I_2	I_3	I_4	I_5	Subconjunto formado	$p(u)$	$I_1 p(u)$	$I_2 p(u)$	$I_3 p(u)$	$I_4 p(u)$	$I_5 p(u)$
1	1	1	0	0	0	(Cristiano, Messi)	0,11	0,11	0,11	0	0	0
2	1	0	1	0	0	(Cristiano, Falcao)	0,1	0,1	0	0,1	0	0
3	1	0	0	1	0	(Cristiano, Iniesta)	0,08	0,08	0	0	0,08	0
4	1	0	0	0	1	(Cristiano, Xavi)	0,2	0,2	0	0	0	0,2
5	0	1	1	0	0	(Messi, Falcao)	0,01	0	0,01	0,01	0	0
6	0	1	0	1	0	(Messi, Iniesta)	0,18	0	0,18	0	0,18	0
7	0	1	0	0	1	(Messi, Xavi)	0,12	0	0,12	0	0	0,12
8	0	0	1	1	0	(Falcao, Iniesta)	0,03	0	0	0,03	0,03	0
9	0	0	1	0	1	(Falcao, Xavi)	0,15	0	0	0,15	0	0,15
10	0	0	0	1	1	(Iniesta, Xavi)	0,02	0	0	0	0,02	0,02
							$\sum_i p(u) = 1$	$\frac{1}{1} 0,49$	$\frac{1}{2} 0,42$	$\frac{1}{3} 0,29$	$\frac{1}{4} 0,31$	$\frac{1}{5} 0,49$
								$E(I) = (\bar{\pi}_1, \bar{\pi}_2, \bar{\pi}_3, \bar{\pi}_4, \bar{\pi}_5)$				

Para Falcao: $I_3(s) = \begin{cases} 1 & \text{si Falcao} \in s \\ 0 & \text{si Falcao} \notin s \end{cases}$

↳ realización de una variable aleatoria S .

$$\bar{\pi}_3(s) = \sum_{s \ni k} p(u) = 0,29$$

En un diseño muestral sin reemplazo $\lambda = \bar{\pi}$, donde $\bar{\pi} = (\bar{\pi}_1, \bar{\pi}_2, \dots, \bar{\pi}_k)$ es el vector de probabilidades de inclusión resultante del diseño de muestreo.

Entonces $x = E(S) = \sum_{s \in Q} p(u)s$

↳ Esperanza de la probabilidad de inclusión de primer orden:

$$E(I_k) = \bar{\pi}_k \rightsquigarrow E(I_{k|s}) = \sum_{s \ni k} p(u) I_{k|s} \Rightarrow E(I_{k|s})$$

$$E(I_{k|s}) = (1) p(k=1) + (0) p(k=0)$$

$$E(I_{k|s}) = p(k=1)$$

$$E(I_{k|s}) = p(k \in s) = \sum_{s \ni k} p(u)$$

$$\boxed{E(I_k) = \bar{\pi}_k}$$

→ Esperanza de la muestra aleatoria de primer orden:

$$E(S) = \sum_{s \in S} s_i p(s_i) = n(s) \quad \text{Magnitud del vector? ??}$$

$$= \vec{s}_1 p(s_1) + \vec{s}_2 p(s_2) + \dots + \vec{s}_{n(q)} p(s_{n(q)})$$

la esperanza de la muestra es el vector de probabilidades de inclusión de primer orden.

$$E(S) = (\pi_1, \pi_2, \dots, \pi_N)'_{N \times 1}$$

► PROBABILIDAD DE INCLUSIÓN DE SEGUNDO ORDEN (Π_{KL})

Acabamos a determinar qué es la probabilidad de inclusión de dos o más elementos a la vez en la muestra.

$$\Pi_{KL} = P(K \in S \wedge L \in S)$$

$$= P(I_K(s) I_L(s))$$

$$= \sum_{s \in K \cap L} p(s)$$

$$E(I_K(s) I_L(s)) = \Pi_{KL}$$

$$= \sum_{s \in K \cap L} I_K(s) I_L(s) p(s)$$

Ej: En el ejemplo anterior

$$\Pi_{muestra} = \Pi_{2,1} = 0,18$$

► MATRIZ DE PROBABILIDADES DE INCLUSIÓN:

$$\begin{pmatrix} \Pi_{11} & \Pi_{12} & \Pi_{13} & \dots & \Pi_{1N} \\ \Pi_{21} & \Pi_{22} & \Pi_{23} & \dots & \Pi_{2N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \Pi_{N1} & \Pi_{N2} & \dots & \dots & \Pi_{NN} \end{pmatrix}$$

Es una matriz simétrica con las probabilidades de inclusión de primer orden en su trazo y las probabilidades de inclusión de segundo orden en el resto de sus posiciones.

El trazo de las probabilidades de inclusión se calculan como:

$$\frac{(N^2 - N)}{2} + N = \frac{N^2 - N}{2} + \frac{2N}{2} = \boxed{\frac{N(N+1)}{2}}$$

► LA ESTADÍSTICA IK.

Este estadística forma valores aleatorios segun si el diseño de muestreo es con reemplazamiento o sin reemplazamiento.

↳ PROPIEDADES.

$$\bullet E(I_k) = \pi_k$$

$$\bullet V(I_k) = \pi_k(1 - \pi_k) ; \text{ demostración.}$$

$$V(I_{k(S)}) = E[(I_{k(S)} - E(I_{k(S)}))^2]$$

$$= E(I_{k(S)}^2) - [E(I_{k(S)})]^2$$

Como:

$$I_{k(S)} = \begin{cases} 1 & \text{si } k \in S \\ 0 & \text{si } k \notin S \end{cases}$$

$$I_{k(S)}^2 = \begin{cases} 1^2 & \text{si } k \in S \\ 0^2 & \text{si } k \notin S \end{cases}$$

entonces

$$I_{k(S)}^2 = I_k , \text{ por lo que.}$$

$$V(I_{k(S)}) = E(I_k) - [E(I_k)]^2$$

$$V(I_k) = \boxed{= \pi_k - \pi_k^2 = \pi_k(1 - \pi_k)}$$

$$\bullet \text{Cov}(I_k, I_L) = \pi_{KL} - \pi_k \pi_L \quad \rightarrow \text{ojo, normalmente } \pi_{KL} \neq \pi_k \pi_L$$

Demostración

$$\text{Cov}(I_k, I_L) = E(I_k I_L) - E(I_k) E(I_L)$$

$$= (1) P(I_k I_L = 1) + (0) P(I_k I_L = 0) - \pi_k \pi_L$$

$$\boxed{\text{Cov}(I_k, I_L) = \pi_{KL} - \pi_k \pi_L} = \underline{\Delta_{KL}}$$

► PARÁMETROS POBLACIONALES:

Un parámetro poblacional es una función de los valores correspondientes a todos los elementos de la población

$$f(y_1, y_2, \dots, y_n) = \theta$$

donde y es la variable de interés.

(o) parámetros de interés q' nos interesan son:

- Total Poblacional (t_y):

$$t_y = \sum_{k \in U} y_k$$

- Promedio Poblacional:

$$\bar{y}_y = \frac{\sum_{k \in U} y_k}{N} = \frac{t_y}{N}$$

- Variancia Poblacional:

$$S_y^2 = \frac{\sum_{k=1}^{N-1} u_k (y_k - \bar{y}_y)^2}{N-1}$$

DOMINIOS:

Un dominio es una subpoblación denotada U_d , tal que:

- $U_{\text{univ}} = \bigcup_{d=1}^D U_d \rightarrow$ un dominio es una partición del universo, entonces el universo se conforma de la unión de los dominios contenidos en él.

→ Esto quiere decir q' no pueden existir elementos q' pertenezcan a más de un dominio.

- $\exists k \in U_1$, entonces $k \notin U_2$, donde U_2 y U_1 son dominios mutuamente excluyentes y $U_2 \cap U_1 = \emptyset$ y $U_2 \cup U_1 = U_{\text{univ}}$.
- El número de elemento(s) pertenecientes a un dominio U_d es N_d , con lo cual llamamos a $N_d = \text{Tamaño del Dominio}$.
- $P_d = \frac{N_d}{N} \Rightarrow \text{Tamaño Relativo del dominio (P}_d)$.

↳ Parámetros de interés de los dominios:

- Total de un dominio (t_{yd}):

$$t_{yd} = \sum_k y_{dk} = \sum_k y_k z_{dk} \quad \text{donde } z_{dk} = \begin{cases} 1 & \text{si } k \in U_d \\ 0 & \text{si } k \notin U_d \end{cases}$$

- Tamaño del dominio (N_d)

$$N_d = \sum_{k \in U_d} z_{dk}$$

- Promedio de la característica de interés en el dominio

$$\bar{y}_{yd} = \frac{t_{yd}}{N_d} = \frac{\sum_k y_{dk}}{N_d}$$

► ESTADÍSTICA $n(S)$: TAMAÑO DE LA MUESTRA:

Es una cantidad aleatoria q' puede ser expresada en función de una estadística de inclusión: $n(S) = \sum_U I_{k(S)}$

↳ Propiedades de Interés:

- $E[n(S)] = \sum_k \pi_k$

ya que:

$$E[n(S)] = E\left[\sum_k I_k\right] = \sum_k E(I_k) = \sum_k \pi_k$$

- $V[n(S)] = \sum_k \pi_k - (\sum_k \pi_k)^2 + \sum_{k \neq l} \sum_{k \neq l} \pi_k \pi_l$

ya que:

$V[n(S)] = V\left[\sum_k I_k\right] \rightarrow$ la varianza de una suma es igual a la suma de las variancias más su covarianza

$$= \sum_k V(I_k) + \sum_{k \neq l} \sum_{k \neq l} \text{cov}(I_k, I_l)$$

$\pi_k(1-\pi_k)$

$$= \sum_k \pi_k - \sum_k \pi_k^2 + \sum_{k \neq l} \sum_{k \neq l} \underbrace{\text{cov}(I_k, I_l)}_{\pi_k(1-\pi_k)}$$

$$= \sum_k \pi_k - \left[\sum_k \pi_k\right]^2 + \sum_{k \neq l} \sum_{k \neq l} \pi_k \pi_l - \cancel{\sum_{k \neq l} \sum_{k \neq l} \pi_k \pi_l}$$

$$V[n(S)] = \sum_k \pi_k - \left[\sum_k \pi_k\right]^2 + \sum_{k \neq l} \sum_{k \neq l} \pi_k \pi_l$$

-//— RECORDANDO —//—

$$V[x_i + x_j] = V(x_i) + V(x_j) + \text{cov}(x_i, x_j) + \text{cov}(x_j, x_i)$$

$= V(x_i) + V(x_j) + 2 \text{cov}(x_i, x_j)$, utilizando la matriz de varianzas y covarianzas:

$$\begin{pmatrix} 1 & & & & \\ 2 & \cancel{\begin{pmatrix} 1_1^2 & 1_1 1_2 & 1_1 1_3 & \dots & 1_1 p \\ 1_2 1_1 & 1_2^2 & 1_2 1_3 & \dots & 1_2 p \\ 1_3 1_1 & 1_3 1_2 & 1_3^2 & \dots & 1_3 p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ p 1_1 & p 1_2 & p 1_3 & \dots & p^2 \end{pmatrix}} & & & & \end{pmatrix}$$

$$\Rightarrow V(x_i + x_j) = \sum_i V(x_i) + \sum_{i \neq j} \sum_{i \neq j} \text{cov}(x_i, x_j)$$

• Cuando trabajamos un diseño de muestra fijo, tenemos estas propiedades adicionales:

- $E[n(S)] = n \rightarrow E[n(S)] = E(n) = n \rightarrow$ la esperanza de una constante es ella misma.

- $\sum_{k \in U} \pi_{kL} = n \pi_L \rightarrow$
$$\begin{aligned} \sum_{k \in U} \pi_{kL} &= \sum_{k \in U} E[l_k(S) l_L(S)] \\ &= \sum_{k \in U} \left[\sum_{s \in Q} l_k(s) l_L(s) p(s) \right] \\ &= \sum_{s \in Q} \left[\sum_{k \in U} l_k(s) l_L(s) p(s) \right] \\ &= \sum_{s \in Q} l_L(s) p(s) \sum_{k \in U} l_k(s) \underbrace{\sum_{k \in U} l_k(s)}_n \\ &= n \sum_{s \in Q} l_L(s) p(s) \underbrace{\pi_L}_{\text{def}} \end{aligned}$$

$$\boxed{\sum_{k \in U} \pi_{kL} = n \pi_L}$$

- $\sum_{L \in U} \pi_{kL} = n \pi_k \Rightarrow$
$$\begin{aligned} \sum_{L \in U} \pi_{kL} &= \sum_{L \in U} E(l_k(S) l_L(S)) \\ &= \sum_{L \in U} \left[\sum_{s \in Q} l_k(s) l_L(s) p(s) \right] \\ &= \sum_{s \in Q} \left[\sum_{L \in U} l_k(s) l_L(s) p(s) \right] \\ &= \sum_{s \in Q} l_k(s) p(s) \sum_{L \in U} l_L(s) \underbrace{\sum_{L \in U} l_L(s)}_n \\ &= n \sum_{s \in Q} l_k(s) p(s) \underbrace{\pi_k}_{\text{def}} \end{aligned}$$

$$\boxed{\sum_{L \in U} \pi_{kL} = n \pi_k}$$

- $\sum_{k \in U} \Delta_{kL} = 0 \Rightarrow$
$$\begin{aligned} \sum_{k \in U} \pi_{kL} - \pi_k \pi_L &= 0 \\ \sum_{k \in U} \pi_{kL} - \pi_L \sum_{k \in U} \pi_k &= 0 \quad \text{com} \end{aligned}$$

$$\begin{aligned} \sum_{k \in U} \pi_{kL} - n \pi_L &= 0 \\ \underbrace{n \pi_L - n \pi_L}_0 &\rightarrow (\text{ver propiedad anterior}) \\ n \pi_L - n \pi_L &= 0 \end{aligned}$$

$$\sum_{k \in U} \Delta_{kk} = 0 \Rightarrow \sum_{k \in U} \Pi_{kk} - \Pi_{kk}\Pi_k = 0$$

$$\sum_{k \in U} \Pi_{kk} - \Pi_k \sum_{k \in U} \Pi_k = 0$$

$$n\Pi_k - n\Pi_k = 0$$

$$\rightarrow \Pi_k(1-\Pi_k) = \sum_{k \neq L} \Pi_{kk}\Pi_L - \Pi_{kk} = -\sum_{k \neq L} \text{cov}(I_k, I_L)$$

Para demostrar esta propiedad, es necesario redifinir el tamaño de la muestra
si $n = \sum_k I_k \Rightarrow n = I_L + \sum_{k \neq L} I_k$

$$\text{y q' } \Pi_k(1-\Pi_k) \stackrel{\text{var}(I_k)}{\Rightarrow} \text{cov}(I_k, I_k) \Rightarrow \Pi_k(1-\Pi_k) = \text{cov}(I_k, n - \sum_{k \neq L} I_k)$$

$$\text{ya q' } n = I_L + \sum_{k \neq L} I_k \Rightarrow I_L = n - \sum_{k \neq L} I_k$$

entonces:

Recordando q':

$$\text{cov}(x_k, \sum_{i \neq k} x_i) = \text{cov}(x_k, x_1 x_2 + \dots + x_{k-1} + x_k + \dots) \\ = \sum_i \text{cov}(x_k, x_i)$$

y recordando q':

$$\text{cov}(x, a - \sum y_i) = \sum_i \text{cov}(x, -y_i) \\ = - \sum_i \text{cov}(x, y_i)$$

tendriamos q'

$$\text{cov}(I_k, n - \sum_{k \neq L} I_k) = -\sum_{k \neq L} \text{cov}(I_k, I_k)$$

$$= -\sum_{k \neq L} \Pi_{kk} - \Pi_{kk}\Pi_k$$

$$= \sum_{k \neq L} \Pi_{kk}\Pi_k - \Pi_{kk}$$

► ESTIMADOR DE HORVITZ-THOMPSON: se utilizó para calcular totales de población aplicando un factor de expansión al total muestral.

$$\hat{t}_{HT} = \sum_s \frac{y_k}{\Pi_k} \Rightarrow \boxed{\hat{t}_{HT} = \sum_s d_k y_k} \text{ con } d_k = \frac{1}{\Pi_k}$$

Teniendo en cuenta que $\Pi_k = \sum_s p(s) \quad \text{y} \quad p(s) = \frac{n}{N}$ entonces

$$\hat{t}_{HT} = \sum_s \sum_s \frac{N}{n} y_k \Rightarrow \hat{t}_{HT} = \frac{N}{n} \sum_s y_k \Rightarrow \boxed{\hat{t}_{HT} = N \bar{y}_k}$$

Las Propiedades del Estimador Horvitz-Thompson:

- Esperanza del estimador: Teniendo en cuenta que

$$\hat{t}_k y_k = \sum_j \frac{y_k}{\pi_{jk}} = \sum_j l_{jk} \frac{y_k}{\pi_{jk}}$$

entonces

$$E(\hat{t}_k y_k) = E\left(\sum_j l_{jk} \frac{y_k}{\pi_{jk}}\right) = \sum_j \frac{y_k}{\pi_{jk}} E(l_{jk}) = \sum_j \frac{y_k}{\pi_{jk}} \pi_{jk}$$

$$E(\hat{t}_k y_k) = \sum_j y_k = \hat{t}_k$$

- Varianza del estimador:

$$V(\hat{t}_k y_k) = V\left(\sum_j l_{jk} \frac{y_k}{\pi_{jk}}\right)$$

$$= \sum_j \frac{y_k^2}{\pi_{jk}^2} V(l_{jk}) + \sum_{k \neq L} \sum_j \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}} \text{cov}(l_{jk}, l_{jL})$$

$$\therefore \sum_j \frac{y_k^2}{\pi_{jk}^2} \text{cov}(l_{jk}, l_{jk})$$

$$= \sum_j \frac{y_k^2}{\pi_{jk}^2} [\pi_{jk}(1 - \pi_{jk})] + \sum_{k \neq L} \sum_j \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}} [\pi_{jkl} - \pi_{jk}\pi_{jL}]$$

$$= \sum_j \frac{y_k^2}{\pi_{jk}^2} [\pi_{jk} - \pi_{jk}^2] + \sum_{k \neq L} \sum_j \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}} \Delta_{kl}$$

$$= \sum_j \left[\frac{y_k^2 \pi_{jk}}{\pi_{jk}^2} - \frac{y_k^2 \pi_{jk}^2}{\pi_{jk}^2} \right] + \sum_{k \neq L} \sum_j \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}} \Delta_{kl}$$

$$\therefore \hat{t}_k = \sum_j \left[\frac{y_k^2}{\pi_{jk}} - y_k^2 \right] + \sum_{k \neq L} \sum_j \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}} \Delta_{kl}$$

$$V_1(\hat{t}_k y_k) = \sum_j \sum_{k \neq L} \Delta_{kl} \frac{y_k}{\pi_{jk}} \frac{y_L}{\pi_{jL}}$$

$$\text{o } V_1(\hat{t}_k y_k) = \sum_j \sum_l \left(\frac{\pi_{jk}}{\pi_{jk}\pi_{jl}} y_k y_l - \left(\sum_k y_k \right)^2 \right)$$

- Si el diseño $\rho(\cdot)$ es de tamaño fijo, entonces la varianza del estimador HT se escrbe.

$$V_2(\hat{t}_k y_k) = -\frac{1}{2} \sum_j \sum_l \Delta_{kl} \left(\frac{y_k}{\pi_{jk}} - \frac{y_l}{\pi_{jl}} \right)^2$$

↳ Estimador Alternativo de Ben-Yates-Groves.

Nombre: Robert Moreno

Código: 2113124

Estadística - Muestreo

Ejercicio: Para $n=5$ y $m=3$ calcular el total de la población mediante el estimador Horvitz Thompson.

$\hat{L} \rightarrow L$

$s_i = 1$	Mussi, Beckham, Cristiano, Etto, Rooney	$\pi_{11} = 0,68$	$y_1 = 1,72$	$l_1 = 1,282$	$\bar{l}_1 = 1,223$
$s_i = 1$	Herrera, Beckham, Cristiano	$\pi_{12} = 0,17$	$y_2 = 0,68$	$l_2 = 0,44$	$\bar{l}_2 = 0,436$
$s_i = 1$	Herrera, Beckham, Cristiano	$\pi_{13} = 0,17$	$y_3 = 0,68$	$l_3 = 0,44$	$\bar{l}_3 = 0,436$
$s_i = 1$	Mussi, Beckham, Cristiano	$\pi_{21} = 0,17$	$y_1 = 1,72$	$l_1 = 1,282$	$\bar{l}_1 = 1,223$
$s_i = 1$	(Herrera, Beckham, Cristiano, Etto)	$\pi_{22} = 0,17$	$y_2 = 0,68$	$l_2 = 0,44$	$\bar{l}_2 = 0,436$
$s_i = 1$	(Herrera, Beckham, Cristiano, Etto, Rooney)	$\pi_{23} = 0,17$	$y_3 = 0,68$	$l_3 = 0,44$	$\bar{l}_3 = 0,436$
$s_i = 1$	Mussi, Beckham, Cristiano, Etto	$\pi_{31} = 0,17$	$y_1 = 1,72$	$l_1 = 1,282$	$\bar{l}_1 = 1,223$
$s_i = 1$	(Herrera, Beckham, Cristiano, Etto, Rooney)	$\pi_{32} = 0,17$	$y_2 = 0,68$	$l_2 = 0,44$	$\bar{l}_2 = 0,436$
$s_i = 1$	(Herrera, Beckham, Cristiano, Etto, Rooney)	$\pi_{33} = 0,17$	$y_3 = 0,68$	$l_3 = 0,44$	$\bar{l}_3 = 0,436$

$$\text{JUERTE:}$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{11} = 0,68$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{12} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{13} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{21} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{22} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{23} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{31} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{32} = 0,17$$

$$\sum_{k=1}^m p_{kj} = 1 \Rightarrow p_{33} = 0,17$$

$$p_{11} = 0,68 \quad \pi_{11} = 0,68 \quad l_1 = 1,282$$

$$p_{12} = 0,17 \quad \pi_{12} = 0,17 \quad l_2 = 0,44$$

$$p_{13} = 0,17 \quad \pi_{13} = 0,17 \quad l_3 = 0,44$$

$$p_{21} = 0,17 \quad \pi_{21} = 0,17 \quad l_1 = 1,282$$

$$p_{22} = 0,17 \quad \pi_{22} = 0,17 \quad l_2 = 0,44$$

$$p_{23} = 0,17 \quad \pi_{23} = 0,17 \quad l_3 = 0,44$$

$$p_{31} = 0,17 \quad \pi_{31} = 0,17 \quad l_1 = 1,282$$

$$p_{32} = 0,17 \quad \pi_{32} = 0,17 \quad l_2 = 0,44$$

$$p_{33} = 0,17 \quad \pi_{33} = 0,17 \quad l_3 = 0,44$$

$$\pi_k = \sum_{j=1}^n f_{jk} g_j p_{kj} \quad t_{kp} = \sum_{j=1}^n k f_{jk} g_j \pi_{kj}$$

$$\mathbb{E}(f_{kp}) = \frac{\sum f_{kp}}{\sum g_j} \pi_k$$

$$\text{Var}(t_{kp}) = \sum_{k=1}^m \pi_k [(t_{kp}) - \mathbb{E}(t_{kp})]^2$$

$$\mathbb{E}(\hat{L}_{HT}) = 13,56$$

www.ipso.com.co

$$\sum_{j=1}^n p_{kj} = 1$$

$$\sum_k \pi_k = n = 3$$

$$\mathbb{E}(\hat{L}_{HT}) = 13,56$$

$$\text{Var}(\hat{L}_{HT}) = 14,25$$

↳ Estimación de la Varianza del estimador Horvitz-Thompson:

Si todos los $\pi_{kL} > 0$ entonces los estimadores inferiores de $V_1(\hat{t}_{\text{HT}})$ y $V_2(\hat{t}_{\text{HT}})$ son los siguientes:

$$\hat{V}_1(\hat{t}_{\text{HT}}) = \sum_s \sum_k \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L}$$

$$\hat{V}_2(\hat{t}_{\text{HT}}) = \sum_s \sum_{kL} \frac{\Delta_{kL}}{\pi_{kL}} \left(\frac{y_k}{\pi_k} - \frac{y_L}{\pi_L} \right)^2 \left(-\frac{1}{2} \right)$$

La estimación se hace a través de un total expandido y la varianza se va a calcular en la muestra sobre la varianza expandida.

Vamos a ver q' el estimador de la varianza Horvitz Thompson es inferior, para esto:

$$V_1(\hat{t}_{\text{HT}}) = \sum_s \sum_k \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L}$$

$$V_1(\hat{t}_{\text{HT}}) = \sum_s \sum_{kL} I_{kL} \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L} \quad \text{con } I_{kL} = \begin{cases} 1 & \text{si } k \wedge L \in s \\ 0 & \text{en otro caso.} \end{cases}$$

entonces el valor esperado de $V_1(\hat{t}_{\text{HT}})$ =

$$\begin{aligned} E(V_1(\hat{t}_{\text{HT}})) &= E \left(\sum_s \sum_{kL} I_{kL} \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L} \right) \\ &= \sum_s \sum_{kL} E(I_{kL}) \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L} \end{aligned}$$

$$= (1) \sum_s \sum_{kL} P(I_{kL}=1 \wedge I_{kL}=1) \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L} + (0) \sum_s \sum_{kL} P(I_{kL}=0 \wedge I_{kL}=0) \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L}$$

$$= \sum_s \sum_{kL} P(I_{kL}=1 \wedge I_{kL}=1) \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L}$$

$$= \sum_s \sum_{kL} \pi_{kL} \frac{\Delta_{kL}}{\pi_{kL}} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L}$$

$$E[V_1(\hat{t}_{\text{HT}})] = \sum_s \sum_{kL} \Delta_{kL} \frac{y_k}{\pi_k} \frac{y_L}{\pi_L} \quad \text{y análogamente se hace para } V_2(\hat{t}_{\text{HT}})$$

Burnham (1998) resalta que:

- Si $\pi_{kL} \neq 0$ y $k \neq L$, pero si $\pi_{kL} = 0$ y $k \neq L \notin s$, entonces no se puede garantizar el inferioridad de los anteriores expresiones.
- Es posible q' $\hat{V}_1(\hat{t}_{\text{HT}}) < 0$ o $\hat{V}_2(\hat{t}_{\text{HT}}) < 0$, resultados q' no pueden ser interpretados o usados. Para evitar esto es necesario q' $\Delta_{kL} \leq 0$ y $k \neq L$
- No necesariamente las estimaciones arrojadas por las anteriores expresiones coinciden en todos los casos.

↳ C.V.E:

$$\hat{C.V.E} = \frac{\sqrt{V(\hat{t}_{\pi})}}{\hat{t}_{\pi}} * 100 \quad y \text{ con total estimado } C.V. = \frac{\sqrt{V(t_{\pi})}}{t_{\pi}} * 100$$

↳ Estimador alternativo para la varianza del Total Poblacional Estimado

$$V_2(\hat{t}_{\pi}) = -\frac{1}{2} \sum_j \sum_k \Delta_{kk} \left(\frac{y_k}{\pi_{kk}} - \frac{y_j}{\pi_{kj}} \right)^2 \rightsquigarrow \text{solo para diseño de tamaño fijo.}$$

$$\hat{V}_2(t_{\pi}) = -\frac{1}{2} \sum_j \sum_k \frac{\Delta_{kk}}{\pi_{kk}} \left(\frac{y_k}{\pi_{kk}} - \frac{y_j}{\pi_{kj}} \right)^2$$

► ESTIMACION DE OTROS PARAMETROS:

↳ Estimación del Tamaño de la Población:

En general cuando nos enfocamos a una investigación por muestras, se desconoce el total de la población. En este caso podemos utilizar el estimador de Horvitz-Thompson para realizar dicha estimación, puesto q' N puede ser escrito como:

$$N = \sum_j 1 \quad ó \quad N = \sum_j y_k^+ \quad \text{donde } y_k^+ = \begin{cases} 1 & \text{para todo } k \in U \\ 0 & \text{en otro caso} \end{cases}$$

por lo cual

$$\hat{N}_{\pi} = \sum_j \frac{y_k^+}{\pi_{kk}} \quad \text{y} \quad \hat{N}_{\pi} = \sum_j \frac{1}{\pi_{kk}}$$

donde $E(\hat{N}_{\pi}) = N$

$$V(\hat{N}_{\pi}) = \sum_j \sum_k \Delta_{kk} \frac{1}{\pi_{kk}} \frac{1}{\pi_{kk}}$$

$$\hat{V}(\hat{N}_{\pi}) = \sum_j \sum_k \Delta_{kk} \frac{1}{\pi_{kk}} \frac{1}{\pi_{kk}}$$

• Tomar todas las muestras generadas de un espacio con $N=7$ y $n=4$ y estime \hat{N} para cada una de las 35 muestras.

↳ Estimación de un Promedio con N Conocido:

En el espacio poblacional: $\bar{y}_0 = \frac{1}{N} \sum_0 y_k \Rightarrow \bar{y}_0 = \frac{1}{N} \cdot 48$
Entonces:

En el espacio muestral:

$$\hat{y}_{\pi} = \frac{1}{N} \sum_j \frac{y_k}{\pi_{kk}}$$

↳ Estimación de un Promedio con N Desconocido:

$$\hat{Y}_{\pi H} = \frac{1}{N_{\pi}} \sum_j \frac{y_k}{\pi_{kk}} \Rightarrow \hat{Y}_{\pi H} = \frac{\sum_j y_k / \pi_{kk}}{\sum_j 1 / \pi_{kk}}$$

↳ Estimación de Horvitz

↳ Variancia del Promedio Muestral Estimado con N conocido:

$$\hat{\bar{Y}}_H = \frac{1}{N} \sum_s \frac{y_k}{\pi_{kL}}$$

$$V(\hat{\bar{Y}}_H) = V\left(\frac{1}{N} \sum_s \frac{y_k}{\pi_{kL}}\right)$$

$$V(\hat{\bar{Y}}_H) = \frac{1}{N^2} V\left(\sum_s \frac{y_k}{\pi_{kL}}\right)$$

$$V(\hat{\bar{Y}}_H) = \frac{1}{N^2} \left[\sum_v \sum_s \Delta_{vL} \frac{y_k}{\pi_{kL}} \frac{y_L}{\pi_{vL}} \right]$$

↳ Variancia Estimada del Promedio Muestral Estimado con N conocido.

$$\hat{V}(\hat{\bar{Y}}_H) = \frac{1}{N^2} \left[\sum_v \sum_s \frac{\Delta_{vL}}{\pi_{kL}} \frac{y_k}{\pi_{kL}} \frac{y_L}{\pi_{vL}} \right]$$

↳ Estimación de una Proporción con N conocido:

En el espacio poblacional $\rho = \frac{1}{N} \sum_j z_k$ con $z_k = \begin{cases} 1 & \text{si tiene la característica} \\ 0 & \text{en otro caso} \end{cases}$

En el espacio muestral

$$\hat{\rho} = \frac{1}{n} \sum_s \frac{z_k}{\pi_{kL}}$$

donde • $E(\hat{\rho}) = \rho$

$$\bullet V(\hat{\rho}) = V\left(\frac{1}{n} \sum_s \frac{z_k}{\pi_{kL}}\right)$$

$$V(\hat{\rho}) = \frac{1}{n^2} V\left(\sum_s \frac{z_k}{\pi_{kL}}\right)$$

$$V(\hat{\rho}) = \frac{1}{n^2} \left[\sum_v \sum_s \Delta_{vL} \frac{z_k}{\pi_{kL}} \frac{z_L}{\pi_{vL}} \right]$$

$$\bullet \hat{V}(\hat{\rho}) = \frac{1}{n^2} \left[\sum_v \sum_s \frac{\Delta_{vL}}{\pi_{kL}} \frac{z_k}{\pi_{kL}} \frac{z_L}{\pi_{vL}} \right]$$

→ Intervalos de Confianza:

$$t \in t_{\text{y}\pi}^{\wedge} \pm \sqrt{V(t_{\text{y}\pi}^{\wedge})} \cdot t_{1-\alpha/2}$$

Como es un poco encontrar los $V_{\text{y}\pi}$ grados de libertad de t , por lo cual se approxima a t . Por lo tanto:

$$t \in t_{\text{y}\pi}^{\wedge} \pm 2_{1-\alpha/2} \sqrt{V(t_{\text{y}\pi}^{\wedge})}$$

Notese q si sea $t_{\text{y}\pi}^{\wedge}$ factor comuna, entonces.

$$t \in t_{\text{y}\pi}^{\wedge} [\pm 2_{1-\alpha/2} \text{CV}(t_{\text{y}\pi}^{\wedge})]$$

Asi mismo:

$$t \in t_{\text{y}\pi}^{\wedge} \pm 2_{1-\alpha/2} \sqrt{V(t_{\text{y}\pi}^{\wedge})}$$

Error Estándar de $t_{\text{y}\pi}^{\wedge}$
Márgen de Error.

► MUESTREO CON REEMPLAZAMIENTO

como:

$$\vec{s} = \begin{pmatrix} s_1 \\ s_2 \\ \vdots \\ s_n \end{pmatrix} \in \mathbb{N}^{n+}$$

Una muestra con reemplazo se denota como $\binom{N^m-1}{m}$

$$\text{con } \#Q = \binom{m+N-1}{m} = \binom{m+N-1}{N-1}$$

De manera general un diseño de muestreo con reemplazo se define como:

$$p(s) = \begin{cases} \frac{m!}{n_1(s)! n_2(s)! \dots n_N(s)!} p_1^{n_1(s)} p_2^{n_2(s)} \dots p_N^{n_N(s)} & \text{si } \sum_k n_k(s) = m \\ 0 & \text{en otro caso} \end{cases}$$

Ejemplo: Si tenemos un experimento con m ensayos independientes. Si tenemos m experimentos independientes, con posibles resultados e_1, e_2, \dots, e_N , entonces.

1	P_r	2	P_r	3	P_r	m	P_r
e_1	p_1	e_1	p_1	e_1	p_1		e_1	p_1
e_2	p_2	e_2	p_2	e_2	p_2		e_2	p_2
e_3	p_3	e_3	p_3	e_3	p_3		e_3	p_3
e_4	p_4	e_4	p_4	e_4	p_4		e_4	p_4
e_5	p_5	e_5	p_5	e_5	p_5		e_5	p_5
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots		\vdots	\vdots
$= 1 - P_K$	P_K	$\frac{P_K}{P_K}$	$\frac{P_K}{P_K}$	$\frac{P_K}{P_K}$	$\frac{P_K}{P_K}$		$\frac{P_K}{P_K}$	$\frac{P_K}{P_K}$

La probabilidad de inclusión del elemento $e_K = P_K$, es decir la probabilidad de no inclusión del e_K es $= 1 - P_K$

Y a cada uno de estos posibles resultados en cada experimento se tiene asociada su respectiva probabilidad

$\sum p(s) = 1$

$1 - P_K - P_K = \text{la Probabilidad de q' y k no estén en la muestra.}$

www.ipso.com.co

↳ Probabilidad de Inclusión de Primer Orden

$$\Pi_K = 1 - (1 - p_K)^m$$

Ya q' cada evento independiente tiene asociada una probabilidad de éxito p_K cuando $K \in S$, entonces cada uno de estos sorteos aleatorios está determinado por una probabilidad tipo Bernoulli. Por lo tanto, cuando se realizan m ensayos independientes, se utiliza la distribución de probabilidad binomial para hallar las probabilidades de inclusión de primer orden.

$$\Pi_K = P(K \in S) = 1 - P(K \notin S)$$

$$= 1 - \binom{m}{m} (1 - p_K)^m (p_K)^{m-m}$$

$$\boxed{\Pi_K = 1 - (1 - p_K)^m}$$

↳ Probabilidad de Inclusión de Segundo Orden:

$$\Pi_{KL} = P(K \in S \wedge L \in S)$$

Recordando las leyes de Morgan donde $A \wedge B = (A^c \cup B^c)^c$
entonces tenemos que:

$$\Pi_{KL} = 1 - P(K \notin S \cup L \notin S)$$

$$\Pi_{KL} = 1 - [P(K \notin S) + P(L \notin S) - P(K \notin S \cap L \notin S)]$$

$$P(K \notin S) = (1 - p_K)^m$$

$$P(L \notin S) = (1 - p_L)^m$$

$$P(K \notin S \cap L \notin S) = (1 - p_K - p_L)^m$$

Por lo cual:

$$\boxed{\Pi_{KL} = 1 - (1 - p_K)^m - (1 - p_L)^m + (1 - p_K - p_L)^m}$$

RECORDATORIO

Sia X_1, X_2, \dots, X_N una m.a. iid, con esto tenemos q'

$$E(X_i) = \mu$$

$$V(X_i) = \sigma^2$$

$$\text{cov}(X_i, X_j) = 0$$

Entonces

$$\text{i)} \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{Insegundo para } \mu.$$

$$\text{ii)} V(\bar{X}) = \frac{\sigma^2}{n}$$

$$\text{iii)} \hat{V}(X_i) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

(n-1) es para σ^2

iv). estimador para la variancia de \bar{X}

$$\hat{V}(\bar{X}) = \frac{1}{m} \sum_{i=1}^m (\bar{X}_i - \bar{X})^2$$

... entradas retrogradas

Si M es una V.a $\Rightarrow z_k = \frac{y_{ki}}{p_{ki}} \in U$ con $i = 1, 2, \dots, m$.

entonces se puede definir un espacio de experimentos:

l_1	z_i	P_r	l_1	z_i	P_r	l_1	z_i	P_r	l_1	z_i	P_r	l_1	z_i	P_r			
l_1	y_{11}/p_{11}	$p_{11}=P_1$	l_1	y_{12}/p_{12}	$p_{12}=P_2$	l_1	\dots	\dots	l_1	y_{1m}/p_{1m}	$p_{1m}=P_m$	l_1	y_{21}/p_{21}	$p_{21}=P_1$	l_1	y_{22}/p_{22}	$p_{22}=P_2$
l_2	y_{21}/p_{21}	$p_{21}=P_1$	l_2	y_{22}/p_{22}	$p_{22}=P_2$	l_2	\dots	\dots	l_2	y_{2m}/p_{2m}	$p_{2m}=P_m$	l_N	y_{N1}/p_{N1}	$p_{N1}=P_1$	l_N	y_{N2}/p_{N2}	$p_{N2}=P_2$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	
l_N	y_{N1}/p_{N1}	$p_{N1}=P_1$	l_N	y_{N2}/p_{N2}	$p_{N2}=P_2$	l_N	\dots	\dots	l_N	y_{Nm}/p_{Nm}	$p_{Nm}=P_m$	l_N	y_{N1}/p_{N1}	$p_{N1}=P_1$	l_N	y_{N2}/p_{N2}	$p_{N2}=P_2$

Entonces se deduce de estb tabls que:

$$i) P\left(z_i = \frac{y_{ki}}{p_{ki}}\right) = P_{ki}$$

Además que:

$$ii) E(z_i) = ty \Rightarrow E(z_i) = \sum_k \left(\frac{y_k}{p_k} \right) p_k = \sum_k y_k = ty.$$

$$iii) V(z_i) = \sum_k \left(\frac{y_k}{p_k} - ty \right)^2 \cdot p_k \Rightarrow \sigma^2 = \sum_k (z_i - E(z_i))^2 \cdot p_k$$

↳ Estimador de Hansen Horwitz:

$$\bar{z}_i = \frac{1}{M} \sum_{i=1}^m z_i \Rightarrow \bar{z} = \frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k}$$

entonces:

$$\hat{ty}_p = \frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k}$$

Un estimador "natural" para ty es

• El estimador de Hansen Horwitz tiene las siguientes propiedades:

$$\begin{aligned} i) E(\hat{ty}_p) &= E\left(\frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k}\right) \\ &= \frac{1}{m} \sum_{k=1}^m E\left(\frac{y_k}{p_k}\right) \\ &= \frac{1}{m} \sum_{k=1}^m E(z_i) \\ &= \frac{1}{m} \sum_{k=1}^m ty. \\ &= \frac{m}{m} ty \Rightarrow E(\hat{ty}_p) = ty \end{aligned}$$

$$\begin{aligned}
 \text{i)} V(\hat{t}_{yp}) &= V\left(\frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k}\right) \\
 &= \frac{1}{m^2} \sum_{k=1}^m V\left(\frac{y_k}{p_k}\right) \\
 &= \frac{1}{m^2} \sum_{k=1}^m E((z_i - E(z_i))^2) \\
 &= \frac{1}{m^2} m E(z_i - E(z_i))^2 \\
 &= \frac{1}{m} E(z_i - E(z_i))^2 \\
 &= \frac{1}{m} \sum_{k=1}^N (z_i - t_y)^2 p_k
 \end{aligned}$$

Ejercicios de
diferenciación

$$V(\hat{t}_{yp}) = \frac{1}{m} \sum_{k=1}^N \left(\frac{y_k}{p_k} - t_y \right)^2 p_k$$

↳ Varianza estimada de \hat{t}_{yp} :

$$\hat{V}(\hat{t}_{yp}) = \frac{1}{m(m-1)} \sum_{k=1}^m \left(\frac{y_k}{p_k} - \hat{t}_y \right)^2$$

→ x q tengo q calcular un parámetro.

Ejemplo:

Exp 1 Exp 2 Exp 3 Exp 4

$$\begin{array}{llll}
 y_k & 172 & 182 & 175 \\
 p_k & \frac{1}{60} & \frac{3}{60} & \frac{1}{60}
 \end{array}$$

$$z_i = \frac{y_k}{p_k} \quad 172(30) \quad 182(20) \quad 175(60) \quad 157(70)$$

→ Factor de Expansión.

→ En Excel la varianza de \hat{t}_y es:
 $V(\hat{t}_y) = \frac{1}{4} * \text{VAR}(\text{ })$

⊗ (CONTINUA):

p_k debe ser proporcional a y_k ($p_k \propto y_k$), es decir

$$p_k = C y_k, \text{ tal que}$$

$$t_y = \sum_{k=1}^N y_k, \text{ entonces}$$

$$t_y = \sum_{k=1}^N \frac{p_k}{C}$$

$$\sum_{k=1}^N p_k = 1, \text{ entonces}$$

$$t_y = \frac{1}{C}$$

$$V(\hat{t}_y) = \frac{1}{m} \sum_{k=1}^N \left(\frac{y_k}{C} - t_y \right)^2 p_k$$

$$V(\hat{t}_y) = \frac{1}{m} \sum_{k=1}^N \left(\frac{1}{C} - \frac{1}{C} \right)^2 p_k$$

$$V(\hat{t}_y) = 0$$

→ Como elegimos \hat{p}_k ? Los elementos que contribuyen más al total tienen mayor probabilidad de selección; pero como no conocemos muchas veces los valores de y_k , entonces buscamos una variable auxiliar altamente correlacionada con y_k y así poder dar correspondencia a la relación $y_k \sim p_k$. Esto se utiliza para muestreo PPT.

④⑤ Concentración:

Una muestra no necesariamente se tiene que parecer a la población.

→ Estimación del Tamaño en muestras con reemplazo:

$$N = \sum y_k^* \text{ donde } y_k^* = 1 \text{ si } k \in U$$

entonces; $\hat{t}_{yp} = \frac{1}{m} \sum \frac{y_k^*}{p_k}$

Recordar que $p_k \propto y_k$ por lo que

entonces:

$$p_k = Cy_k$$

④⑥ entonces

$$= \frac{1}{m} \sum \frac{y_k^*}{Cy_k}$$

$$= \frac{1}{m} \sum \frac{1}{C} \Rightarrow \text{como } \sum p_k = 1 = C = \frac{1}{N} \Rightarrow p_k = \frac{y_k}{N}$$

En pocas palabras,

$$\hat{t}_{yp} = \frac{1}{m} \sum \frac{1}{\frac{1}{N}} \Rightarrow \hat{t}_{yp} = \frac{1}{m} \sum N \Rightarrow \hat{t}_{yp} = \frac{1}{m} mN$$

$\hat{t}_{yp} = N$

Esto quiere decir que si no se conoce N realmente, no se debe utilizar el estimador de Hansen Horwitz

Esto implica que lo que es \hat{x}, \hat{p} y \hat{N} no es adecuado estimarlo con \hat{t}_{yp} , a no ser que se conozca el tamaño real de la población.

④⑦

\hat{t}_{yp} puede superar ampliamente a \hat{t}_{yp} si $p_k \propto y_k$, como y_k generalmente no se conoce utilizaremos una variable auxiliar x_k , tal que $|\text{Cor}(x_k, y_k)| \approx 1$ y $p_k \propto x_k$ igualmente.

- MUESTREO ALATORIO SIMPLE SIN REEMPLAZO:
- Tiene las siguientes características:
- Sin reemplazo
 - De tamaño fijo
 - Sirve para poblaciones homogéneas en su variable a medir
- $$CV_y = \frac{S_y}{\bar{y}} \cdot 100 \leq 5\% \quad (\text{para } k \leq 20\%)$$

- Se seleccionan los elementos directamente del marco muestral.
- El tamaño del roporte es $\binom{N}{n} = n_k$. Cada uno de los elementos del roporte tiene la misma probabilidad $p(j) = 1/k$ de ser seleccionado, donde k es el número de posibles muestras.

$$p(j) = \frac{1}{\binom{N}{n}}$$

- Todos los diseños de muestrazgo se comparan con este, ya q' el MAS es el diseño de referencia. Si mi diseño pierde con el MAS entonces el diseño planeado no sirve.
- Cuando las poblaciones no son homogéneas, este diseño no es eficiente para estimar parámetros (μ_y, \bar{x}, \dots)
- Esta comparación se hace a través del efecto de diseño ($deff$)

$$deff = \frac{V(\text{diseño Q}(\hat{\theta}))}{V(\text{MAS}(\hat{\theta}))}$$

$deff < 1$	Diseño Q más eficiente
$deff = 1$	Igual
$deff > 1$	MAS más eficiente.

Si $deff < 1$ significa q' el otro diseño se más eficiente.

Ejemplo: Si $V_{MAS} = 200$ $\Rightarrow deff = 2 \rightarrow$ Esto quiere decir q' el otro diseño es 2 veces más eficiente.

- Si no hay información auxiliar de la variable a estimar, use MAS.
- Dentro de los diseños q' no usan información auxiliar es el mejor.

↳ Algoritmos de selección:

El objetivo de un algoritmo de selección es otorgar una probabilidad de selección a cada elemento del roporte.

⇒ Coordenadas Negativas: [Grauer (1997)]

lk	Uk (Identifico)
1	U_1
2	U_2
3	U_3
\vdots	\vdots
N	U_N

$$\text{con } U_{lk} \sim U(0, 1) \Rightarrow$$

lk	Uk (Identifico)	→ no la muestra se constituye por los primeros n elementos.
18	U_1	
5	U_2	
15	U_3	
\vdots	\vdots	
1	U_N	

Pasos:

- ① Generar n valores U_k , $k=1, \dots, n$ donde $U_k \sim U(0,1)$
- ② Asociar a cada U_k un valor C_k
- ③ Ordenar de manera ascendente/descendente los valores C_k
- ④ Los primeros/ $\frac{n}{N}$ últimos n elementos son los que constituyen la muestra

⇒ Fann-Muller - Rechazos (1962).

- ① Generar $\xi \sim U(0,1)$
- ② Calcular $c = \frac{n-\alpha}{N-k+1}$ donde $\alpha =$ tamaño de la muestra antes del paso k
- ③ Si $\xi < C_k$ se selecciona el elemento, si no NO.
- ④ Esto se hace desde $k=1$ hasta obtener la muestra de tamaño n .

Ej: $N=30$ $n=7$

• $k=1$

$$\xi = 0,5099, \quad C_1 = \frac{7-0}{30-1+1} = \frac{7}{30} = 0,23$$

$C_1 < \xi \rightarrow$ NO SE SELECCIONA

• $k=2$

$$\xi = 0,034, \quad C_2 = \frac{7-0}{30-2+1} = \frac{7}{29} = 0,24$$

$C_2 > \xi \rightarrow$ SE SELECCIONA

• $k=3$

$$\xi = 0,542, \quad C_3 = \frac{7-1}{30-3+1} = \frac{6}{28} = 0,21$$

$C_3 < \xi \rightarrow$ NO SE SELECCIONA

OJO: y así sucesivamente hasta seleccionar $n=7$.

Este algoritmo garantiza $\frac{1}{n!}$ probabilidad a cada elemento de ser seleccionado.

↳ PROBABILIDAD DE INCLUSIÓN DE PRIMER ORDEN EN MAS:

$$\begin{aligned}\pi_k &= P(k \text{ es}) = P(I_{k(n)} = 1) = \sum_{s \in k} p(s) = \frac{\binom{1}{1} \binom{n-1}{n-1}}{\binom{n}{n}} \\ &= \frac{(n-1)!}{\frac{(n-1-n+1)!(n-1)!}{n!}} = \frac{(n-1)! n!}{(n-1)! N!} = \frac{n!}{(n-1)!} \frac{(n-1)!}{N!} = n \cdot \frac{1}{N} \Rightarrow\end{aligned}$$

$$\boxed{\Rightarrow \pi_k = \frac{n}{N}}$$

↳ PROBABILIDAD DE INCLUSIÓN DE SEGUNDO ORDEN EN MAS:

$$\begin{aligned}\Pi_{KL} &= P(K \wedge L \in S) = P(I_{K(L)} I_{K(L)} = 1) \\ &= \sum_S p(S) = \frac{\binom{N-2}{n-2}}{\binom{N}{n}} = \frac{(N-2)!}{(N-2-n)! (n-2)!} \\ &= \frac{n!}{(n-2)! N!} = \frac{n(n-1)}{N(N-1)} \Rightarrow \boxed{\Pi_{KL} = \frac{n(n-1)}{N(N-1)}}\end{aligned}$$

↳ ΔKL de MAS

$$\Delta_{KL} = \Pi_{KL} - \Pi_K \Pi_L$$

Si $K=L$

$$\Delta_{KK} = \Pi_K (1 - \Pi_K)$$

Si $K \neq L$

$$\Delta_{KL} = \Pi_{KL} - \Pi_K \Pi_L$$

$$\Delta_K = \frac{n}{N} \left[1 - \frac{n}{N} \right] = \frac{n(N-n)}{N^2}$$

$$\Delta_{KL} = \frac{n(n-1)}{N(N-1)} - \frac{n^2}{N^2} = \frac{-n(N-n)}{N^2(N-1)}$$

Corrector de finitud para poblaciones finitas.

↳ ESTIMADOR DE Horvitz-Z- Thompson:

$$\hat{t}_{\bar{Y}H} = \sum_S \frac{y_K}{\pi_K} \quad \text{como } \bar{\Pi}_K = \frac{n}{N}, \text{ entonces:}$$

$$\hat{t}_{\bar{Y}H} = \left(\frac{N}{n} \right) \sum_S \frac{y_K}{\pi_K} \quad \text{donde } \left(\frac{N}{n} \sum_S \frac{y_K}{\pi_K} \right) \rightarrow \bar{Y}_S$$

entonces Factor de expansión.

$$\hat{t}_{\bar{Y}H} = N \bar{Y}_S$$

↳ Varianza de $\hat{t}_{\bar{Y}H}$.

$$\begin{aligned}V(\hat{t}_{\bar{Y}H}) &= V(N \bar{Y}_S) \\ &= N^2 V(\bar{Y}_S) \\ &= \frac{N^2}{n^2} V\left(\sum_S \frac{y_K}{\pi_K}\right) \\ &= \frac{N^2}{n^2} V\left(\sum_k t_{kH} y_K\right)\end{aligned}$$

donde t_{kH} es la variable aleatoria, entonces teniendo en cuenta que es la varianza de una suma

$$\begin{aligned}&\text{y dado que } V\left(\sum_n x_n\right) = \sum_n V(x_n) + \sum_{i \neq j} \text{cov}(x_i, x_j), \\ &\text{entonces: } \\ &= \frac{N^2}{n^2} \left[\sum_N V(y_K) + \sum_{K \neq L} \text{cov}(y_K, y_L) \right]\end{aligned}$$

$$= \frac{N^2}{n^2} \left[\underbrace{\sum_k \gamma_k^2 V(1_k)}_{\textcircled{a}} + \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l \underbrace{\text{cov}(1_k, 1_l)}_{\textcircled{b}} \right]$$

→ Dado q' $\textcircled{a} \Rightarrow V(1_k) = \begin{cases} \pi_k - \pi_k^2 & \text{si } k = k \\ \pi_n - \pi_k \pi_l & \text{si } k \neq l \end{cases}$ entonces.

$$= \frac{N^2}{n^2} \left[\frac{n(n-n)}{N^2} \sum_k \gamma_k^2 - \frac{n(n-n)}{N^2(N-1)} \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l \right]$$

$$= \frac{N^2}{n^2} \left(\frac{n(n-n)}{N^2} \right) \left[\sum_k \gamma_k^2 - \frac{1}{N-1} \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l \right]$$

$$= \frac{N}{N} \frac{N-n}{n} \left[\sum_k \gamma_k^2 - \frac{1}{N-1} \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l \right]$$

Usando la identidad.

$$\sum_k (\gamma_k - \bar{\gamma}_0)^2 = \sum_k \gamma_k^2 - \frac{(\sum_k \gamma_k)^2}{N} = \frac{1}{N} \left[(N-1) \sum_k \gamma_k^2 - \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l \right]$$

entonces q'

$$\sum_k \gamma_k^2 - \frac{1}{N-1} \sum_{k \neq l} \sum_{k,l} \gamma_k \gamma_l = \frac{N}{N-1} \sum_k (\gamma_k - \bar{\gamma}_0)^2$$

entonces.

$$= \frac{N}{N} \frac{(N-n)}{n} \left[\frac{N}{N-1} \sum_k (\gamma_k - \bar{\gamma}_0)^2 \right] = \frac{N^2}{N} \frac{(N-n)}{n} \left[\frac{1}{N-1} \sum_k (\gamma_k - \bar{\gamma}_0)^2 \right]$$

$$= \frac{N^3 - N^2 n}{Nn} S_{y_u}^2 = \frac{N^3}{Nn} \left[1 - \frac{n}{N} \right] S_{y_u}^2$$

$$\tilde{V} = V(\hat{t}_{\text{MAS}}) = \frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{y_u}^2 \quad \text{donde } \frac{n}{N} = \text{Fracci\'on de muestreo.}$$

Corrector de finitos.

$$\tilde{V}(\hat{t}_{\text{PI}}) = \frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{y_s}^2 \quad \text{con } S_{y_s}^2 = \sum_s \frac{(\gamma_k - \bar{\gamma}_s)^2}{N-1}$$

Para demostrar su insesamiento bastar\'ia con hacer

$$\begin{aligned} E(\tilde{V}(\hat{t}_{\text{PI}})) &= E \left(\frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{y_s}^2 \right) \\ &= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) E(S_{y_s}^2) \end{aligned}$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) E \left(\frac{1}{n-1} \sum_{k=1}^{n-1} (\bar{y}_k - \hat{y}_k)^2 \right)$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) E \left(\frac{2}{3} \bar{y}_k^2 - n \bar{y}_k^2 \right)$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) \left[E \left(\frac{2}{3} \bar{y}_k^2 \right) - n E \left(\bar{y}_k^2 \right) \right]$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) \left[E \left(\frac{2}{3} \sum_{k=1}^{n-1} (\bar{y}_k)^2 \right) - n E \left[\frac{\hat{t} \hat{y}_{\pi}}{N^2} \right] \right]$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) \left[\frac{n}{N} \sum_{k=1}^{n-1} \bar{y}_k^2 - \frac{n}{N^2} E(\hat{t} \hat{y}_{\pi})^2 \right]$$

donde $E(\hat{t} \hat{y}_{\pi})^2 = V(\hat{t} \hat{y}_{\pi}) + t^2$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) \left[\frac{n}{N} \sum_{k=1}^{n-1} \bar{y}_k^2 - \frac{n}{N^2} \left[\frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2 + t^2 \right] \right]$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{1}{n-1} \right) \left[\frac{n}{N} \sum_{k=1}^{n-1} \bar{y}_k^2 - \frac{n}{N^2} \left(\frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2 + t^2 \right) \right]$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{n}{n-1} \right) \left[\frac{1}{N} \sum_{k=1}^{n-1} \bar{y}_k^2 - \frac{1}{N^2} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2 - \frac{1}{N^2} t^2 \right]$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \left(\frac{n}{n-1} \right) \left(\frac{1}{N} \left(\frac{2}{3} \bar{y}_{\pi}^2 - \frac{\sum_{k=1}^{n-1} \bar{y}_k^2}{N} \right) - \frac{N-n}{N} S_{\bar{y}_{\pi}}^2 \right)$$

$$= \frac{N^2}{n} \left(1 - \frac{n}{N} \right) \frac{n}{n-1} \left[\frac{N-1}{N} S_{\bar{y}_{\pi}}^2 - \frac{N-n}{N} S_{\bar{y}_{\pi}}^2 \right] \Rightarrow = \frac{N^2}{n} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2 = E(\hat{t} \hat{y}_{\pi})^2 = V(\hat{t} \hat{y}_{\pi})$$

Estimación de la media Poblacional

$$\hat{\bar{y}}_{\pi} = \frac{\hat{t} \hat{y}_{\pi}}{N} = \frac{\sum_{k=1}^{n-1} \bar{y}_k}{n} = \bar{y}_S$$

$$V(\hat{\bar{y}}_{\pi}) = \frac{1}{n} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2$$

$$V(\hat{\bar{y}}_{\pi}) = \frac{1}{n} \left(1 - \frac{n}{N} \right) S_{\bar{y}_{\pi}}^2$$

Intervalo de Confianza

$$IC(\bar{y}) = \bar{y} \pm t_{n-1, 1-\alpha/2} \sqrt{V(\bar{y})}$$

$$IC(\hat{t} \hat{y}_{\pi}) = \hat{t} \hat{y}_{\pi} \pm t_{n-1, 1-\alpha/2} \sqrt{V(\hat{t} \hat{y}_{\pi})}$$

→ Cuando el tamaño de la muestra es suficiente
el t grande ($> \sqrt{N}$) el percentil t puede
cambiar por el correspondiente valor del
percentil \hat{z} .

→ Coeficiente de Variación:

$$CV = \frac{\sqrt{V(t_{\text{mín}})}}{t_y}$$

$$\hat{CV} = \frac{\sqrt{V(t_{\text{mín}})}}{t_y \pi}$$

- La varianza del estimador \rightarrow proporcional a la varianza de los datos.
- La precisión depende de S_{yu}
- Si $t_y = 0$ no hay varianza.

→ TAMAÑO DE LA MUESTRA PARA MEJIAS Y TOTALLES:

Bajo NMS sin reemplazo, tenemos q:

$$IC(\bar{y}_s) = \bar{y}_s \pm Z_{1-\alpha/2} \frac{S_{yu}}{\sqrt{n}} \sqrt{1 - \frac{n}{N}}$$

y como generalmente no se conoce S_{yu} se sustituye por S_{ys} .

$$(1) \text{ Exprimiendo } Z_{1-\alpha/2} \frac{S_{yu}}{\sqrt{n}} \sqrt{1 - \frac{n}{N}} = \text{Márgen de Error} = e$$

entonces para decidir sobre la precisión mínima de la investigación tenemos que

$$Pr\{|\bar{y}_s - \bar{y}_v| \leq e\} = 1 - \alpha$$

$$Pr\{-e \leq \bar{y}_s - \bar{y}_v \leq e\} = 1 - \alpha$$

Por lo tanto la cantidad a minimizar es e :

$$e = Z_{1-\alpha/2} \frac{S_{yu}}{\sqrt{n}} \sqrt{1 - \frac{n}{N}}$$

$$\sqrt{n} = Z_{1-\alpha/2} \frac{S_{yu}}{e} \sqrt{1 - \frac{n}{N}} \Rightarrow n = \frac{e^2}{Z^2} \frac{S_{yu}^2}{e^2} \left(1 - \frac{n}{N}\right)$$

$$n = \frac{Z^2 S_{yu}^2}{e^2 N} = \frac{n}{N} \frac{Z^2 S_{yu}^2}{e^2}$$

$$n + \frac{n}{N} \frac{Z^2 S_{yu}^2}{e^2} = \frac{Z^2 S_{yu}^2}{e^2 N} = n \left(1 + \frac{Z^2 S_{yu}^2}{N e^2}\right) = \frac{Z^2 S_{yu}^2}{e^2 N}$$

Si $n_0 = \frac{Z^2 S_{yu}^2}{e^2}$ tenemos que

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

\Rightarrow Tamaño de muestra cuando se desea combinar el Error mínimo absoluto.

y donde las confidencias Z y e son previamente establecidas por el investigador.

• Tamaño de la Muestra Controlando el Error Máximo Relativo:

En algunos ocasiones es difícil lograr una precisión relativa, aunque en estos casos el tamaño de muestra es frecuentemente mayor q cuando se desea controlar el error máximo absoluto.

El error máximo relativo se define como:

$$\epsilon = \frac{\bar{q}_s - \bar{q}_v}{\bar{q}_v} = \frac{e}{\bar{q}_v} \quad \text{entonces}$$

$$Pr\left(\left|\frac{\bar{q}_s - \bar{q}_v}{\bar{q}_v}\right| \leq \epsilon\right) = 1 - \alpha$$

$$Pr\left(|\bar{q}_s - \bar{q}_v| \leq \epsilon |\bar{q}_v|\right) = 1 - \alpha$$

entonces:

$$\epsilon |\bar{q}_v| = Z_{1-\alpha/2} \frac{s_y}{\sqrt{n}} \sqrt{1 - \frac{n}{N}}$$

y despejando n se tiene:

$$n \geq \frac{k_0}{1 + \frac{k_0}{N}}$$

$$\text{con } k_0 = \frac{Z_{1-\alpha/2}^2 S_y^2}{\epsilon^2 \bar{q}_v^2} \rightarrow CV^2$$

entonces $k_0 = \frac{Z_{1-\alpha/2}^2 CV^2}{\epsilon^2} \Rightarrow$ si la población es muy grande q N/n es despreciable

por lo cual si N es muy grande podemos escribir:

$$k_0 = \frac{Z^2 CV^2}{\epsilon^2}$$

después de un poco de álgebra se puede aproximar por

$$k_0 = \frac{CV^2}{CV(\bar{q})^2}$$

donde $CV(\bar{q})$ es el CV deseado para la media muestral.

• Consideración:

El S_{y_p} lo puedo calcular de otros estudios, una prueba piloto o medianas simulaciones según la distribución q' se cree tiene la variable de interés.

• generalmente $e = 5\%$
 $CV = 5\%$

↳ Tamaño de muestra segun CV:

$$CV = \sqrt{\frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_y^2}$$

despejando n tenemos q':

$$n = \frac{CV^2 N^2}{CV_y^2 + N}$$

• Consideración:

• Si la muestra piloto no es tomada intencionalmente atendiendo a los criterios del experto, entonces:

$$n = \frac{Z^2 S_y^2}{e^2} \left(1 + \frac{2}{n_1}\right)$$

donde n_1 = tamaño de la prueba piloto.

y $\frac{2}{n_1}$ es el precio q' se paga por el desconocimiento de S_y^2 .

Ejemplo:

Se quiere estimar el ingreso mensual de una población y para determinar el tamaño muestral se tomó una muestra piloto con la siguiente información:

$$N = 10000 \quad S_y^2 = 6,059 \quad (\text{Varianza de la muestra Piloto})$$

$$n_1 = 30 \quad (\text{tamaño de la muestra piloto}). \quad Z = 2,45$$

- a). Si la muestra piloto fue seleccionada por un experto, y se deseó conocer el tamaño de muestra mínimo para estimar el ingreso promedio y total de la comunidad con un ERROR ABSOLUTO no mayor a 0,2 salarios mínimos (2000 en el caso del total) y una confiabilidad mínima del 95%, como se realizaría dicho cálculo?

$$n = \frac{n_0}{1 + \frac{n_0}{N}}$$

donde $n_0 = \frac{Z^2 S_y^2}{e^2}$

$$n = \frac{1,96^2 \cdot 6,059}{0,2^2} = \frac{1}{\frac{1}{10000} \left(\frac{1,96^2 \cdot 6,059}{0,2^2} \right)} = 549,91 \approx 550$$

= 549,91 es el número de personas q' se deben seleccionar sin incluir a la muestra piloto.

b) Considera q' la muestra piloto es una MAS. Bajo las mismas condiciones, ¿cuál sería el tamaño de la muestra final?

$$n = \frac{z^2 S_p^2}{e^2} \left(1 + \frac{2}{n_1}\right) \Rightarrow n = \frac{1,96^2 \cdot 6,059}{0,05^2} \cdot \left(1 + \frac{2}{30}\right) = 620,70 \approx 621$$

Lo cual indica q' hay q' sacar 621 personas adicionales a las ya seleccionadas.

c) Si lo q' se desea es controlar el ERROR RELATIVO antes q' el absoluto y se busca q' este sea como máximo del 5% y adicionalmente se conoce q' se conoce una estimación, apriori de la media y la varianza q' serán dadas por la muestra piloto, cuál sería el tamaño de la muestra?

$$n = \frac{k_0}{1 + \frac{k_0}{N}} \quad \text{con } k_0 = \frac{z^2 CV^2}{e^2}$$

$$k_0 = 1,96^2 \cdot \frac{\left(\sqrt{6,059}\right)^2}{0,05^2} = 290,961784$$

$$n = \frac{1,290,961784}{1 + \frac{1,290,961784}{10000}} = 282,05 \approx \boxed{283} \rightarrow \text{siempre se approxima al mayor}$$

DISEÑO MUESTRAL BERNOLLI:

Se utiliza para revisar por ejemplo cosechas de variotípico o incertidumbres → se requiere usar punto muestral q' regresen una decisión en el momento mismo.

En este existen N experimentos en los cuales se decide la selección o no selección de cada elemento de \cup .

↳ Diseño de muestras:

$$p(s) = \begin{cases} \pi^{n(s)} (1-\pi)^{N-n(s)} & \text{si } s \text{ tiene tamaño igual a } n(s) \\ 0 & \text{en otro caso.} \end{cases}$$

Si s tiene tamaño igual a $n(s)$ > donde $n(s)$ es la variable aleatoria.

donde $\pi = \pi_{\text{ex}} + K \epsilon u$ y $\sum_{s \in \cup} p(s) = 1$

↳ Algoritmo de selección:

1) Fijar el valor de π tal q' $0 < \pi < 1$

2) Obtener $E_k \sim U(0,1)$ $\forall k=1, 2, \dots, N$

3) Si elemento k -ésimo pertenece a la muestra con $P_k = \pi$. Es decir si $E_k < \pi$ el individuo k -ésimo es seleccionado.

↳ Tamaño del Reporte:

- Definiendo Q_r como el reporte que contiene todos los posibles muestras de tamaño $r=n$, tenemos

$$\# Q_r = \binom{N}{r}$$

- Definiendo Q como el reporte que contiene todos los posibles muestras de tamaño entre $r=0$ y $r=N$

$$\# Q = \sum_{r=0}^N \binom{N}{r} = 2^N$$

↳ Distribución del tamaño de la muestra:

Bajo Bernoulli, $n(s) \sim \text{Bin}(r, \pi)$

$$P(n(s)=r) = \sum_{s \in Q_r} p(s) = \binom{N}{r} \pi^r (1-\pi)^{N-r}$$

con $r=1, 2, \dots, N$ y Q_r el reporte que contiene todos los posibles muestras de tamaño r , donde $Q_r \subset Q$.

- En $p(s)$ Bernoulli no hay manera de calcular el tamaño de la muestra.

$$E(n(s)) = N\pi$$

$$V(n(s)) = N\pi(1-\pi)$$

↳ Probabilidad de inclusión de primer orden

Teniendo en cuenta que $\pi_k = P(K \in s)$, tenemos que

$$\pi_k = \sum_{s \in Q} I_{k \in s} p(s)$$

$$\pi_k = 0 \cdot p(s_0) + \binom{N-1}{0} p(s_1) + \binom{N-1}{1} p(s_2) + \dots + \binom{N-1}{r-1} p(s_r) + \binom{N-1}{N-1} p(s_N)$$

$$= \binom{N-1}{0} \pi^0 (1-\pi)^{N-1} + \binom{N-1}{1} \pi^1 (1-\pi)^{N-2} + \dots + \binom{N-1}{r-1} \pi^r (1-\pi)^{N-r} + \binom{N-1}{N-1} \pi^{N-1} (1-\pi)^0$$

$$\pi_k = \sum_{r=1}^N \binom{N-1}{r-1} \pi^r (1-\pi)^{N-r}$$

$$= \sum_{r=0}^{N-1} \binom{N-1}{r} \pi^{r+1} (1-\pi)^{N-(r+1)} = \pi \sum_{r=0}^{N-1} \binom{N-1}{r} \pi^r (1-\pi)^{N-r-1}$$

entonces $\boxed{\pi_k = \pi}$.

→ Probabilidad de inclusión de 2º orden.

$$\Pi_{KL} = P(K \wedge L \in S) = \sum_{n=0}^N p(S_0) + \sum_{n=1}^N p(S_1) + \sum_{n=2}^N p(S_2) + \binom{N-2}{1} p(S_3) + \binom{N-2}{2} p(S_4) + \dots + \binom{N-2}{r-2} p(S_r) + \binom{N-2}{N-2} p(S_N)$$

entonces

$$\Pi_{KL} = \sum_{r=2}^N \binom{N-2}{r-2} \pi^r (1-\pi)^{N-r}$$

$$\Pi_{KL} = \sum_{r=0}^{N-2} \binom{N-2}{r} \pi^{r+2} (1-\pi)^{N-(r+2)}$$

$$\Pi_{KL} = \pi^2 \sum_{r=0}^{N-2} \binom{N-2}{r} \pi^r (1-\pi)^{N-2-r}$$

$$\Pi_{KL} = \pi^2$$

↳ Estimador de Horvitz-Thompson

- $\hat{t}_{\text{HT}} = \sum_k \frac{y_k}{\pi_k}$

- $V(\hat{t}_{\text{HT}}) = \sum_j \sum_{k \neq l} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}$ con $\Delta_{kl} = \Pi_{kl} - \Pi_k \Pi_l$

$$\Delta_{kl} = \begin{cases} 0 & \text{si } k \neq l \\ \pi(1-\pi) & \text{si } k = l = l \end{cases}$$

entonces con $k=l$

$$V(\hat{t}_{\text{HT}}) = \sum_j \sum_{k \neq l} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}$$

$$= \frac{\pi(1-\pi)}{\pi^2} \sum_k y_k^2 \Rightarrow \boxed{\left(\frac{1}{\pi} - 1 \right) \sum_k y_k^2 = V(\hat{t}_{\text{HT}})}$$

- $\hat{V}(\hat{t}_{\text{HT}})$ con $k=l$

$$\hat{V}(\hat{t}_{\text{HT}}) = \frac{1}{\pi} \left(\frac{1}{\pi} - 1 \right) \sum_k y_k^2$$

- Comentario: ~~HT estimador de H.T para Diseno Bernoulli si inagrupado~~ ~~yo q'~~

ya q' si $n=N$

$$\hat{t}_{\text{HT}} = \frac{1}{\pi} \sum_k y_k = \frac{\bar{y}}{\pi}$$

Objetivo: Se conoce el NIV de impuesto pagado

π (dato)

impuesto como cuadrado
S.P.S (π , dato impuesto)
abajo [res, π]

[res]
[res, π]

sem [1, cuadrado] res.c ('obligado' pagado; 'impuesto')
 $p_{PS}(\pi_e, \pi_e)$

$$\sum_s \sum_s \frac{\pi(1-\pi)}{\pi^4} s^2$$

$$\frac{1-\pi}{\pi^2} \sum_s s^2$$

$$\frac{1-\pi}{\pi^2} - \frac{\pi^2}{\pi^2}$$

$$\frac{\pi(1-\pi)}{\pi^2} \sum_s s^2$$

$$\frac{1-\pi}{\pi^2} - \frac{1}{\pi} = \frac{\pi - \pi^2}{\pi^3} = \frac{\pi(1-\pi)}{\pi^2}$$

$$\hat{P}_{\pi} = \frac{1}{N} \sum_s \frac{2\pi e}{\pi e} \Rightarrow V(\hat{P}_{\pi}) = V(\frac{2\pi}{\pi})$$

= $\frac{1}{N^2} \sum_s \frac{2\pi^2}{\pi^2} V(\pi_e) \Rightarrow$ se habrá visto que
~~que~~ $Cov(\pi_e, \pi_e) = 0$ en KFC

entonces

$$= \frac{1}{N^2} \sum_s \frac{2\pi^2}{\pi^2} \pi(1-\pi)$$

$$V(\hat{P}_{\pi}) = \frac{1}{N^2} \frac{\pi(1-\pi)}{\pi^2} \sum_s 2\pi^2$$

$$V(\hat{P}_{\pi}) = \frac{1}{N^2} \frac{1}{\pi^2} \pi(1-\pi) \sum_s 2\pi^2$$
$$= \frac{1}{N^2} \frac{\pi(1-\pi)}{\pi^2} 2 \cdot 2\pi^2$$
$$= \frac{1}{N^2} \frac{(1-\pi)}{\pi^2} 2 \cdot 2\pi^2$$
$$= \frac{1}{N^2} \frac{2(1-\pi)}{\pi^2}$$

• Estimador alternativo del total.

El estimador alternativo es el estimador del MAS

$$\hat{t}_{ALT}^k = N \bar{y}_S = N \sum_0^n y_k \frac{n}{n}$$

• Comentarios:

+ Diferentes de tamaño de muestra aleatorios suelen ser más ineficientes q' los de tamaño fijo

↳ Efecto Distro.

$$eff(\hat{t}_0) = \frac{V(\hat{\theta}_{BERN})}{V(\hat{\theta}_{MAS})}$$

$$eff(\hat{t}_0) = \frac{(1-\pi) \sum_0^n y_k}{N^2(1-\frac{n}{N}) S_{y_0}^2}$$

dado q' $p(\cdot)$ Bernoulli no tiene tamaño de muestra fijo hacemos de π la fracción de muestra $\pi = n/N$

$$eff(\hat{t}_0) = \frac{(N-n) \sum_0^n y_k}{N^2(1-\frac{n}{N}) S_{y_0}^2} = \frac{(N-n) \sum_0^n y_k}{N^2(N-n) S_{y_0}^2} = \frac{\pi(N-n) \sum_0^n y_k}{N^2 n (N-n) S_{y_0}^2}$$

$$= \frac{(N-n) \sum_0^n y_k}{S_{y_0}^2 (N-n) n N} = \frac{\bar{y}_k}{S_{y_0}^2 N}$$

► ESTIMACION EN DOMINIO. (Andrés Gutiérrez).

Un dominio es una subpoblación específica o subgrupo poblacional q' cumple las siguientes condiciones.

$$1) U_d \subset U \text{ tal q' } U = \bigcup_{d=1}^D U_d$$

$$2) Si k \in U_l \text{ entonces } k \notin U_d \text{ para } d \neq l$$

$$3) El número de elementos en el dominio U_d es N_d y se llama Tamaño Absoluto del Dominio.$$

$$4) El Tamaño Relativo de U_d está dado por P_d = \frac{N_d}{N}$$

- Total de un Dominio.

$$tyd = \sum_{Ud} y_k$$

- Total de la variable de interés en el dominio

$$tyd = \sum_j y_{dk}$$

dónde $y_{dk} = z_{dk} * y_k$ siendo

$$z_{dk} = \begin{cases} 1 & \text{si } k \in Ud \\ 0 & \text{en otro caso.} \end{cases}$$

- Tamaño del Dominio:

$$Nd = \sum_j z_{dk}$$

- Media de la Variable de Interés en el Dominio

$$\bar{y}_{d\pi} = \frac{tyd}{Nd} = \frac{\sum_j y_{dk}}{Nd}$$

→ Estimación del Total de Un Dominio. (de Horvitz Thompson)

- $\hat{tyd\pi} = \frac{N}{n} \sum_s y_{dk} = \frac{N}{n} \sum_{sd} y_k$

- $V(\hat{tyd\pi}) = \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{ydu}^2$

- $\hat{V}(tyd\pi) = \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{yds}^2$

Con S_{ydu}^2 y S_{yds}^2 el estimador de la varianza de los valores de la característica de interés. y_d en el universo y en la muestra.

① Nota: q' en la expresión S_{ydu}^2 los valores q' intervenen son los de la variable de interés si el elemento pertenece al dominio y ceros si el elemento no pertenece al dominio. Por tanto, las anteriores expresiones van a tener valores grandes por la inclusión de ceros. Este es el precio q' se debe pagar por el descensoimiento de la pertenencia de los elementos al dominio.

→ Estimación del tamaño absoluto de un dominio.

- $\hat{Nd\pi} = \frac{N}{n} \sum_s z_{dk} = \frac{N}{n} \sum_{sd} z_k$

- $\hat{V}(Nd\pi) = \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{zdu}^2$

$$\bullet \hat{V}(N\hat{f}_n) = \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{yds}^2 \quad \text{y} \quad \text{a)} \quad S_{yds}^2 = \frac{n}{n-1} \hat{p}_{si} (1 - \hat{p}_{si}) \quad \text{donde } \hat{p} = \frac{n}{N}$$

En las expresiones S_{yds}^2 y S_{yds}^2 los valores que intervienen son 1's si $k \in U_d$ y 0's si $k \notin U_d$.

→ Estimación del Tamaño Relativo de un Dominio

$$\bullet \hat{P}_{dr} = \frac{1}{N} \sum \frac{N}{n} z_{dk} = \frac{1}{n} \sum z_{dk} = \frac{n_d}{n}$$

$$\bullet V(\hat{P}_{dr}) = \frac{1}{n} \left(1 - \frac{n}{N}\right) S_{zdu}^2 \quad \text{p.d. v.u.r.} \quad S_{zdu}^2 = \frac{N \cdot p(1-p)}{N-1} \quad \checkmark$$

$$\bullet \hat{V}(\hat{P}_{dr}) = \frac{1}{n} \left(1 - \frac{n}{N}\right) S_{zds}^2 \quad \text{p.d. v.u.r.} \quad S_{zds}^2 = \frac{n}{n-1} \hat{p}_{si} (1 - \hat{p}_{si}) \quad \checkmark$$

con S_{zdu}^2 y S_{zds}^2 el estimador de la varianza de los valores de la característica de interés yd en el universo y en la muestra.

→ Estimación de la media de un Dominio:

$$\bullet \hat{\bar{y}}_{U_d n} = \frac{N/n \sum s_y y_{dk}}{N_d}$$

$$\bullet V(\hat{\bar{y}}_{U_d n}) = \frac{1}{N_d^2} \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{ydu}^2$$

$$\bullet \hat{V}(\hat{\bar{y}}_{U_d n}) = \frac{1}{N_d^2} \frac{N^2}{n} \left(1 - \frac{n}{N}\right) S_{yds}^2$$

Para poder utilizar este estimador se necesita conocer N_d . En la práctica pocas veces se conoce, por lo cual hay q' utilizar una estimación alternativa

$$\hat{\bar{y}}_{sd} = \frac{\hat{t} \hat{\bar{y}}_{U_d n}}{N_d} = \frac{\sum s_y y_{dk}}{\sum z_{dk}} = \frac{\sum s_y y_k}{N_d} \quad * \Rightarrow \text{Por el momento } V \text{ y } \hat{V} \text{ no se calculan.}$$

$$= N_d \bar{y}_{sd}$$

MUESTREO ALATORIO SIMPLE CON REEMPLAZO.

Sea p_1, p_2, \dots, p_N probabilidades de selección con $p_i = \frac{1}{N}$

"en reemplazo" el tamaño de la muestra puede ser mayor a N^M

$$P\left(\frac{\text{S}^m}{S^N}\right) = \frac{m!}{S_1! S_2! \dots S_m!} p_{S^m}^{S^m} = \frac{m!}{S_1! S_2! \dots S_m!} \left(\frac{1}{N}\right)^{S^m}$$

→ los elementos tienen la misma probabilidad de selección pero las muestras no tienen la misma probabilidad $p(S)$.

Entonces:

$$\cdot p(S) = \begin{cases} \frac{m!}{n_1(S)! n_2(S)! \dots n_m(S)!} \prod \left(\frac{1}{N}\right)^{n_k(S)} & \text{si } \sum n_k(S) = m \\ 0 & \text{en otro caso} \end{cases}$$

• Cardinalidad:

$$\#Q = \binom{N+m-1}{m}$$

• Probabilidad de inclusión de Primer orden

$$\bar{\pi}_k = 1 - \left(1 - \frac{1}{N}\right)^m$$

la $\sum \bar{\pi}_k$ nos da el tamaño efectivo = m ya q' en algunos casos se da q' $m \neq n$.

• PWR estimador

$$\hat{t}_{WP} = \frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k} = \frac{N}{m} \sum_{k=1}^m \frac{y_k}{p_k}$$

Nota: El pwr estimador y el de H-T son iguales en NASR?

NO!!! ... Ya q' acá se tienen en cuenta los elementos repetidos

• Varianza

$$V(\hat{t}_{WP}) = V\left(\frac{1}{m} \sum_{k=1}^m \frac{y_k}{p_k}\right), \text{ haciendo } \frac{y_k}{p_k} = z_i$$

$$= \frac{1}{m^2} \sum_{i=1}^m V(z_i)$$

$$= \frac{1}{m^2} \sum_{i=1}^m E(z_i - E(z_i))^2$$

$$= \frac{1}{m^2} m \cdot E(z_i - E(z_i))^2$$

$$= \frac{1}{m} E(z_i - t_{WP})^2$$

$$\begin{aligned}
&= \frac{1}{m} E \left(\frac{y_k}{p_k} - t_y \right)^2 \\
&= \frac{1}{m} \sum_j \left(\frac{y_k}{p_k} - t_y \right)^2 p_k \\
&= \frac{1}{Nm} \sum_j (Ny_k - ty)^2 \\
&= \frac{1}{Nm} \sum_j (N^2 y_k^2 - 2Ny_k t_y + t_y^2) \\
&= \frac{1}{Nm} N^2 \sum_j (y_k^2 - 2\frac{y_k t_y}{N} + \frac{t_y^2}{N}) \\
&= \frac{N}{m} \sum_j (y_k^2 - 2y_k \bar{y}_0 + \bar{y}_0^2) \\
&= \frac{N}{m} \sum_j (y_k - \bar{y}_0)^2
\end{aligned}$$

$\Rightarrow \boxed{\hat{V}(t_{yp}) = \frac{N(N-1)}{m} S_{y0}^2}$

$\rightarrow \text{con } S_{y0}^2 = \frac{1}{N-1} \sum_j (y_k - \bar{y}_0)^2$

• Estimación de la varianza del estimador pwr

$$\begin{aligned}
\hat{V}(t_{yp}) &= \frac{1}{m(m-1)} \sum_{sr} \left(\frac{y_k}{p_k} - \hat{t}_{yp} \right)^2 \\
&= \frac{1}{m(m-1)} \sum_{sr} (Ny_k - \hat{t}_{yp})^2 \\
&= \frac{N^2}{m(m-1)} \sum_{sr} (y_k - \bar{y}_{sr})^2 \\
&= \frac{N^2 (m-1)}{m(m-1)} S_{y_{sr}}^2 \quad \Rightarrow \quad \boxed{\hat{V}(t_{yp}) = \frac{N^2}{m} S_{y_{sr}}^2}
\end{aligned}$$

$$\text{con } S_{y_{sr}}^2 = \frac{1}{m-1} \sum_{sr} (y_k - \bar{y}_{sr})^2$$

• Algoritmo de selección:

- Método Secuencial de Tille:

seleccionar N_k veces el elemento k -ésimo de acuerdo a una distribución binomial:

$$\text{Bin}(n, p).$$

$$\text{Bin}\left(m - \sum_{i=1}^{k-1} N_i, \frac{1}{N-k+1}\right)$$

donde

m = tamaño de la muestra deseada

k = elemento k -ésimo del piso

N = Universo

Efecto Diseño:

$$d_{eff} = \frac{V(t_{ij})}{V(t_{ij}^n)} \quad \text{si } d_{eff} \begin{cases} > 1 & \text{Más preciso el MAS} \\ < 1 & \text{Más preciso MASE.} \end{cases}$$

Para hacerlos comparables vamos a hacer una restricción $M=n$, es decir, tomamos la muestra efectiva

$$d_{eff} = \frac{\frac{N(N-1)}{m} S_p^2}{\frac{N^2(1-\frac{n}{N}) S_p^2}{n}} = \frac{\frac{N(N-1)}{m}}{\frac{N^2(1-\frac{n}{N})}{n}} = \frac{\frac{N(N-1)}{m}}{\frac{N(N-n)}{n}} = \boxed{= \frac{N-1}{n-n} = d_{eff}}$$

cuando $n \rightarrow N$ $d_{eff} \geq 1$

y si $N \rightarrow \infty$:

$$d_{eff} = \frac{N-1}{N-n} = \frac{1 - \frac{1}{N}}{\left(1 - \frac{n}{N}\right)} = \frac{1}{1 - \frac{n}{N}} = \boxed{= \frac{1}{1-f} = d_{eff}}$$

con $f = \text{fracción de muestras}$.

Porque los diseños de muestra aleatoria pierden con los de tamaño fijo
 \rightarrow Porque en el MAS si aplicamos el factor de corrección por finitud.

MUESTREO SISTEMATICO

$N \rightarrow$ Universo

$n \rightarrow$ Muestra

$a \rightarrow$ # Arranques

$c \rightarrow$ Residuo.

$a \rightarrow$	1	2	3	4	5
y_1	y_2	y_3	y_4	y_5	
y_6	y_7	y_8	y_9	y_{10}	
y_{11}	y_{12}	y_{13}	y_{14}	y_{15}	
y_k	y_{k+1}	y_{k+2}	y_{k+3}	y_{k+4}	

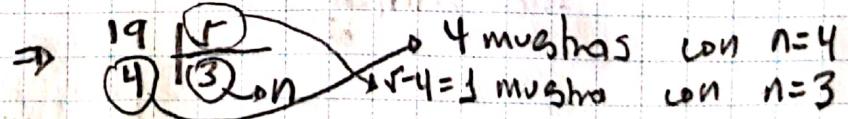
Ej:

Si tengo un universo con 19 elementos
y quiero seleccionar una muestra en 5 etapas:

$a \rightarrow$ Defino el número de grupos
 $n \rightarrow$ Mi muestra

en este ejemplo

$$\begin{array}{l} a=5 \\ n=3 \end{array}$$



entonces $N = an + c$

$$\begin{array}{ccccccc} \downarrow & \downarrow & \downarrow & \downarrow \\ 19 & 5 & 3 & 4 & & & \end{array}$$

con

$$\Rightarrow \# \text{ muestra: } \{n, n+1\}$$

Con cuál diseño me quedo? \Rightarrow Hago MAS para n fijo igual a 1.

entonces

$$c = N - \left\lfloor \frac{N}{a} \right\rfloor a$$

donde $\left\lfloor \frac{N}{a} \right\rfloor$ es la parte entera de la division $\frac{N}{a}$

- $\# Q_r = a$ donde $a = \frac{N}{n}$ cuando $c=0$ ó $a = \left\lfloor \frac{N}{n} \right\rfloor$ cuando $c \neq 0$
- $p(s) = \begin{cases} 1/a & \text{si } s \in Q_r \\ 0 & \text{en otro caso} \end{cases}$
- $\pi_k = \frac{1}{a} \approx \frac{N}{n}$
- $\pi_{KL} = \begin{cases} \frac{1}{a} & \text{si } K \wedge L \in S_r \\ 0 & \text{en otro caso} \end{cases}$
- Estimador de Horvitz Thompson

$$\hat{t}_{HT} = \sum_{S_r} \frac{y_K}{\pi_K} = a \sum_{S_r} y_K = \boxed{a \cdot t_{sr} = \hat{t}_{HT}}$$

$$\hat{t} = a \sum_{S_r} y_K \approx \frac{N}{n} \sum_{S_r} y_K \boxed{\approx N \bar{y}_{sr} = \hat{t}_{HT}}$$

- Varianza del estimador

$$V(\hat{t}_{HT}) = \sum_j \sum_{K,L} \Delta_{KL} \frac{y_K}{\pi_K} \frac{y_L}{\pi_L} = \sum_j \sum_{K,L} (\pi_{KL} - \pi_K \pi_L) \frac{y_K y_L}{\pi_K \pi_L}$$

$$= \sum_j \sum_{K,L} \frac{\pi_{KL} y_K y_L}{\pi_K \pi_L} - y_K y_L \quad \text{como } K \wedge L \text{ tienen q estar en el mismo grupo:}$$

$$= \sum_{r=1}^a \left[\sum_{S_r} \sum_{K,L} \frac{\pi_{KL} y_K y_L}{\pi_K \pi_L} - \left(\sum_j y_K \right)^2 \right]$$

$$= \sum_{r=1}^a \left[\sum_{S_r} \frac{1}{a^2} y_K y_L \right] - \left(\sum_j y_K \right)^2$$

$$= \sum_{r=1}^a \left[a \left(\sum_{S_r} y_K \right)^2 \right] - \left(\sum_j y_K \right)^2$$

$$= a \sum_{r=1}^a \left[\hat{t}_{sr}^2 \right] - \hat{t}_{sr}^2 \quad , \text{vimos anteriormente q' el estimador es q'ado de } \hat{t}_{sr} = N \bar{y}_{sr} \text{, por lo cual}$$

$$= a \sum_{r=1}^a \left[\hat{t}_{sr}^2 \right] - (a \bar{y}_r)^2$$

$$= a \sum_{r=1}^a \left[\hat{t}_{sr}^2 \right] - \left[a \sum_{r=1}^a \frac{y_K}{a} \right]^2 = a \sum_{r=1}^a \left[\hat{t}_{sr}^2 \right] - \left[\sum_{r=1}^a y_K \right]^2$$